

Unidad 1

Métricas Fundamentales. Matriz de confusión y métricas derivadas. Métricas de clasificación (Precision, Recall, F1 Score, Accuracy, Kappa). Métricas de regresión (RMSE, MSE, MAE, MAPE, R2). Curvas ROC. Curvas Precision-Recall. Métricas en escenarios desbalanceados

Error de entrenamiento vs error de generalización

Error de entrenamiento (training error)

Es el error que comete el modelo sobre el **mismo conjunto de datos** que utilizó para aprender. También llamado in-sample error, empirical error, training loss.

- **Qué mide:** Qué tan bien se ajusta el modelo a los ejemplos que ya conoce.
- **En la práctica:** Si un modelo tiene un error de entrenamiento muy bajo, significa que ha aprendido a predecir correctamente casi todas las etiquetas de los datos de entrenamiento.

También llamado *error fuera de muestra* (out-of-sample error), es el error esperado del modelo sobre **datos nuevos** que nunca ha visto antes.

- **Qué mide:** La capacidad del modelo para aplicar los patrones aprendidos a situaciones reales y desconocidas.
- **En la práctica:** Como no conocemos el futuro, solemos estimar este error usando un **conjunto de prueba (test set)** o validación.

1. Fuga de Objetivo (Target Leakage)

Ocurre cuando incluyes variables (features) que contienen información sobre el resultado que se está intentando predecir, pero que **no estarían disponibles** en el momento de hacer la predicción real.

- **Ejemplo:** Se quiere predecir si un cliente va a contratar un seguro. Si se incluye la variable "Número de póliza" en el entrenamiento, el modelo tendrá un éxito del 100%, porque solo alguien que ya *contrató* el seguro tiene un número de póliza. En la vida real, cuando quieras predecir nuevos clientes, no tendrás ese dato.

2. Contaminación entre Entrenamiento y Prueba (Train-Test Contamination)


Sucede cuando los datos del conjunto de prueba (test set) o de validación se mezclan con los de entrenamiento durante el proceso de preparación.

- **Ejemplo:** Calcular la media o el escalado (normalization) usando todo el dataset antes de dividirlo en entrenamiento y prueba. Al hacer esto, el conjunto de entrenamiento ya "conoce" el rango y la distribución de los datos de prueba.


Data leakage

Data leakage happens when information from outside the training dataset is used to train the model, giving it access to information it shouldn't have during the training phase.

Data Leakage Event



Target Leakage




Occurs when the model has access to the target variable or information that would not be available at prediction time

Effect of Data Leakage

1. Overfitting to Training Data
2. Inflated Performance Metrics
3. Misleading Insights
4. Wasted Resources

Train-Test Contamination



Happens when information from the test set gets included in the training process, where the same sample appears in both training and test sets

Common Data Leakage Case


1. Including Future Data in Time-Series Predictions
2. Feature Scaling and Preprocessing Before Splitting
3. Target Leakage Through Derived Features
4. Using the Test Set to Tune the Model

- Target leakage: evitamos este error
 1. No tener variables que surjan de la target (variable a posteriori).
- Train - test contamination: evitamos este error
 1. Separando los datos de train y test al inicio.
 2. Trabajando con Pipeline en scikit-learn
(<https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html>)



Underfitting vs overfitting

Capacidad de un modelo



La **capacidad** es la "flexibilidad" de un modelo o su habilidad para ajustar una amplia variedad de funciones (curvas).

- Un modelo con **baja capacidad** es como una regla rígida: solo puede representar relaciones simples (líneas rectas).
- Un modelo con **alta capacidad** es como un hilo de lana: puede doblarse y contorsionarse para pasar por cada punto de los datos.


El modelo rinde mejor cuando su capacidad coincide con la complejidad real de la tarea. Si la naturaleza del problema es cuadrática (como una parábola), un modelo de grado 9 tendrá demasiada capacidad y "fantaseará" formas complejas donde no las hay para intentar tocar todos los puntos.

Underfitting vs Overfitting

Ajuste óptimo

Ajuste pobre de los datos

El modelo sobreajusta los datos



Aumento de complejidad



Underfitting

Cuando un modelo comete muchos errores en el entrenamiento, decimos que tiene un **alto bias**, que underfittea o que el ajuste es pobre. Esto se puede presentar debido a:

- El modelo es muy simple para los datos.
- Los features, variables (columnas) son poco informativos sobre el problema.

Posibles soluciones:

- Probar un modelo más complejo.
- Mejores Features.
- Conseguir más datos.





Cuando un modelo tiene una buena performance en el set de validación pero mala performance en test, se dice que el modelo **sobreajusta u overfittea**. También se dice que el modelo *memoriza* los datos de entrenamiento por eso no generalizará bien frente a nuevos datos. Un modelo que sobreajusta, tiene una **alta varianza**.

- El modelo es muy complejo para los datos.
- Los features, variables (columnas) son muchas para la cantidad de filas.

Posibles soluciones:

- Probar un modelo más simple.
- Menos Features.
- Conseguir más datos.




Objetivo principal del aprendizaje automático


El objetivo del aprendizaje automático siempre es que pueda **generalizar bien** frente a nuevos datos o datos no vistos por el modelo

Bias variance trade-off

En la práctica, por reducir la varianza, se reduce el bias y viceversa. En otras palabras, por reducir el overfitting, se aumenta el underfitting y viceversa. **A esto llamamos bias variance trade-off**. Por tener un modelo que ajusta de manera perfecta en el set de training, terminamos con un modelo pobre para los datos de test.



Sesgo - varianza




Cuando tenemos un modelo de ML, es deseable que tenga:

- baja varianza
- bajo bias.


Bias variance trade-off

(Bias-Variance Tradeoff - 20) True/False. *State Reasons.* Consider the three line regression fits to the same gray points plotted below. (Model Complexity)




$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

(1)



$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2$$

(2)



$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x + \cdots + \hat{\beta}_{20} x^{20}$$

(3)

- (a) The estimate in (2) has a higher variance than the estimate in (1).
- (b) The estimate in (2) has a higher bias than the estimate in (3).
- (c) The estimate in (3) has the smallest training error among the three.
- (d) The estimate in (1) has the smallest test error among the three.

Métricas Generalidades

Las métricas son medidas cuantitativas que utilizamos para evaluar qué tan bien está funcionando un modelo.

Una métrica nos permite comparar diferentes algoritmos y determinar si el modelo está listo para ser usado en el mundo real o si necesita más ajustes. También utilizamos las métricas para elegir el modelo entre varios modelos entrenados.

La elección de la métrica correcta depende totalmente del **objetivo de la investigación o negocio** o de la naturaleza de tus datos:

- **Evaluar el rendimiento:** ¿Qué tan cerca están las predicciones de la realidad?
- **Optimizar:** Ayudan a ajustar los parámetros del modelo.
- **Comunicar resultados:** Permiten explicar a personas no técnicas qué tan confiable es el sistema.

Métricas para clasificación y regresión

Performance Metrics Categorization

Regression

Mean Absolute Error

Mean Squared Error

Root Mean Squared Error

R-squared

Adjusted R-squared

Mean Absolute Percentage Error

Classification

Accuracy

Balanced Accuracy

Precision

Recall

Specificity

Negative Predictive Value

F1-Score

Matthews Correlation Coefficient

Métricas para regresión

Métricas para regresión

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$


$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{SSR}{SST} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Predicted Value



Actual Value

MAE (Error absoluto medio)

$$MAE = \frac{1}{n} \sum \left| y - \hat{y} \right|$$

Diagram illustrating the MAE formula components:

- $\frac{1}{n}$: Divide by the total number of data points
- $\sum$: Sum of
- y : Actual output value
- $\hat{y}$: Predicted output value
- $|y - \hat{y}|$: The absolute value of the residual

Es la media de la diferencia absoluta entre el valor observado y los valores predichos. El error absoluto medio o MAE es un puntaje lineal, lo que significa que todas las diferencias individuales se ponderan por igual en el promedio. Por ejemplo, la diferencia entre 0 y 10 es el doble de la diferencia entre 0 y 5.

Es robusto a outliers.

MSE (Error cuadrático medio)

$$\text{MSE} = \overset{\text{Mean}}{\frac{1}{n} \sum_{i=1}^n} \left(\overset{\text{Error}}{Y_i - \hat{Y}_i} \right) \overset{\text{Squared}}{^2}$$

MSE es una función diferenciable que facilita la realización de operaciones matemáticas en comparación con una función no diferenciable como MAE. Por lo tanto, en muchos modelos, RMSE se utiliza como métrica predeterminada para calcular la función de pérdida a pesar de ser más difícil de interpretar que MAE.

RMSE (Raíz del error cuadrático medio)

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

Es la raíz cuadrada del MSE. La raíz cuadrada permite que los errores están en la misma escala de medida del valor objetivo.

MAPE (mean absolute percentage error)

$$MAPE = \frac{100\%}{n} \sum \left| \frac{\overbrace{y - \hat{y}}^{\text{The residual}}}{\underbrace{y}_{\text{Each residual is scaled against the actual value}}} \right|$$

The diagram includes several annotations in orange text with lines pointing to specific parts of the formula: 'Multiplying by 100% converts to percentage' points to the '100%' in the numerator; 'The residual' points to the 'y - y-hat' in the numerator of the absolute value; and 'Each residual is scaled against the actual value' points to the 'y' in the denominator of the absolute value.

Una de las métricas más utilizadas para medir la precisión de modelos de **regresión** y pronósticos (forecasting).

A diferencia de otras métricas que te dan el error en las mismas unidades que tus datos (como pesos o metros), el MAPE expresa el error como un **porcentaje**, lo que facilita mucho la comunicación de resultados con personas que no son técnicas.

Resumiendo

Métrica	Sensibilidad a Outliers	Unidades	Interpretación	¿Cuándo usarla?
MAE	Baja (Robusta)	Igual que los datos	Directa: error promedio lineal.	Cuando queremos una métrica estable que no se deje llevar por valores extremos.
MSE	Muy Alta	Unidades al cuadrado	Difícil: los valores suelen ser muy grandes.	Cuando los errores grandes son inaceptables y quieres que el modelo los evite a toda costa.
RMSE	Alta	Igual que los datos	Intuitiva: similar a la desviación estándar de los errores.	Cuando queremos penalizar errores grandes pero necesitas que la unidad sea comprensible.
MAPE	Media	Porcentaje (%)	Muy fácil: indica el error relativo.	Cuando necesitas comparar la precisión entre diferentes conjuntos de datos o escalas.

Métricas para clasificación clases balanceadas

Métricas para clases balanceadas:

- Matriz de confusión
- Exactitud (accuracy)
- Curva ROC

Métricas para clases desbalanceadas:

- Matriz de confusión. Énfasis en el precision / recall
- F score
- Curva Precision-Recall

Métricas para clasificación

- Supongamos que tenemos una población que puede tener dos etiquetas: Positivo y Negativo
- A su vez, disponemos de un modelo en el cual las predicciones no coinciden 100% con las clases verdaderas.

Clases
verdaderas



Predicciones



P = Positivo N= Negativo

Positivos verdaderos

Clases
verdaderas



P = Positivo N= Negativo

Predicciones



Positivos predichos
como positivos

VP

Falsos negativos

Clases
verdaderas



P = Positivo N= Negativo

Predicciones



Positivos predichos
como negativos


FN

Negativos verdaderos

Clases
verdaderas



Predicciones



P = Positivo N= Negativo

Negativos predichos
como negativos

VN

Falsos positivos

Clases
verdaderas



Predicciones



P = Positivo N= Negativo

Negativos predichos
como positivos

FP

Matriz de confusión

Todo lo anterior puede resumirse en la Matriz de Confusión

		Predichos	
		Clase 1	Clase 2
Observados	Clase 1	VP	FN
	Clase 2	FP	VN

 Exactitud = $\frac{VP + VN}{VP + VN + FP + FN}$

 Especificidad = $\frac{VN}{FP + VN}$

 Precisión = $\frac{VP}{VP + FP}$

 Sensibilidad = $\frac{VP}{VP + FN}$


A nivel
predicción

Matriz de confusión

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

Ejemplo

Churn (o tasa de cancelación) es el **porcentaje de clientes o suscriptores que dejan de utilizar los servicios de una empresa** durante un período de tiempo determinado.



Otro ejemplo

		Predicciones	
		POSITIVOS	NEGATIVOS
Observaciones	Positivos	Verdaderos Positivos Algo existe y el modelo lo predice  	Falsos Negativos Error Tipo 2. Algo existe. El modelo no lo predice  
	Negativos	Falsos Positivos Error Tipo 1. Algo no existe. El modelo lo predice como si fuera.  	Verdaderos Negativos Algo no existe y el modelo no lo predice  

En la diagonal principal coinciden la observación y la predicción


La curva ROC relaciona el recall con el ratio de falsos positivos. Es decir, relaciona la sensibilidad de nuestro modelo con los fallos optimistas (clasificar los negativos como positivos). Tiene sentido, ya que generalmente si aumentamos el recall, nuestro modelo tenderá a ser más optimista e introducirá más falsos positivos en la clasificación.

El AUC es conveniente por dos razones:

- Es invariable con respecto a la escala. Mide que tan bien se clasifican las predicciones, en lugar de sus valores absolutos.
- El AUC es invariable con respecto al umbral de clasificación.

Curvas ROC

El **objetivo** es que la curva se acerque lo más posible a la esquina superior izquierda, de manera que aumente el recall




La curva ROC nos permite obtener AUC o área bajo la curva. El AUC oscila entre 0 y 1. Un modelo cuyas predicciones son un 100% incorrectas tiene un AUC de 0; otro cuyas predicciones son un 100% correctas tiene un AUC de 1.

Una curva ROC es apropiada cuando:


- Quiero ver la **performance global** del modelo.
- Quiero **comparar diferentes modelos** a diferentes *thresholds* (umbrales).
- Los valores más pequeños en el eje x del gráfico indican **menos FP** y **más TN**.
- Los valores más grandes en el eje y del gráfico indican **más TP** y **menos FN**.

● Actual Negative
● Actual Positive



	Positivo (pred)	Negativo (pred)	Total
Positivo (obs)	11	0	11
Negativo (obs)	5	14	19
Total	16	14	30

Independiente del umbral seleccionado




Vamos a buscar clasificadores que rankeen:

- **alto en Y**, es decir que tengan una alta sensibilidad (recall), o alta tasa de verdaderos positivos, y
- **bajo en X**, es decir, valores bajos en falsos positivos.

Resumiendo: matriz de confusión

**color/forma: rótulo
verdadero**





**zona sombreada:
predicción**

		Prediction	
		Positive	Negative
Actual value	Positive	True positive 	False negative 
	Negative	False positive 	True negative 

Resumiendo: exactitud (accuracy)

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{All}} = \frac{6 + 8}{20} = 0.7$$



Gentle Reminder:

		Predicted		
		Yes	No	
Actual	Yes	TP	FN	False Negative
	No	FP	TN	True Negative

True Positive (arrow from 'Yes' to 'TP')

False Positive (arrow from 'No' to 'FP')

Resumiendo

Confusion Matrix Components

Below are different components of a confusion matrix for a binary classification task with classes **Positive** and **Negative**.

		Predicted		Total
		Positive	Negative	
Actual	Positive	True positive (TP)	False negative (FN) (Type 2 error)	# positives
	Negative	False positive (FP) (Type 1 error)	True negative (TN)	# negatives
Total		TP + FP	FN + TN	# examples

Confusion Matrix Example

		Predicted		Total
		Positive	Negative	
Actual	Positive	80	40	120
	Negative	20	60	80
Total		100	100	200

Accuracy and Error

$$accuracy = \frac{TP+TN}{TP+FP+TN+FN} = \frac{TP+TN}{\#examples}$$

$$error = \frac{FP+FN}{TP+FP+TN+FN} = \frac{FP+FN}{\#examples}$$

Examples

$$accuracy = \frac{80+60}{200} = \frac{140}{200} = 0.70$$

$$error = \frac{20+40}{200} = \frac{60}{200} = 0.30$$

Precision

$$precision = \frac{TP}{TP+FP}$$

Example

$$precision = \frac{80}{100} = 0.80$$

Recall/TP rate/sensitivity

$$recall = \frac{TP}{TP+FN} = \frac{TP}{\#positives}$$

Example

$$recall = \frac{80}{120} = 0.666$$

F₁ score

$$F_1 = 2 \times \frac{precision \times recall}{precision + recall}$$

Example

$$F_1 = 2 \times \frac{0.8 \times 0.666}{0.8 + 0.666} = 0.727$$

True Negative Rate (specificity)

$$tnr = \frac{TN}{\#negatives}$$

Example

$$specificity = \frac{60}{80} = 0.75$$

False Positive Rate

$$fpr = \frac{FP}{FP+TN} = \frac{FP}{\#negatives}$$

Example

$$fpr = \frac{20}{80} = 0.25$$

False Negative Rate

$$fnr = \frac{FN}{FN+TP} = \frac{FN}{\#positives}$$

Example


$$fnr = \frac{40}{120} = 0.333$$

Métricas para clasificación clases desbalanceadas

Recall o sensibilidad

Es sinónimo decir:


- TPR
- Recall
- Sensitivity

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{6}{6+4} = 0.6$$


$$\text{True Positive Rate} = \text{Recall} = \text{Sensitivity} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

		Predicted	
		Yes	No
Actual	Yes	TP	FN
	No	FP	TN

Precisión

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{6}{6+2} = 0.75$$


$$\text{Precision} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}}$$

		Predicted	
		Yes	No
Actual	Yes	TP	FN
	No	FP	TN

A blue dotted arrow points from the 'TP' cell to the numerator of the Precision formula. A red dotted arrow points from the 'FN' cell to the denominator of the Precision formula.


Uno podría elegir trabajar con métricas de Precision y Recall para un problema desbalanceado. Maximizar la precisión cuando quiero minimizar los falsos positivos y maximizar el recall cuando quiero minimizar los falsos negativos.

Precision: cuando el objetivo es minimizar los falsos positivos.

Recall: cuando el objetivo es minimizar los falsos negativos.

Precision y recall pueden combinarse mediante:

- F score
- Curvas Precision-Recall (curvas PR)



$$F_{\beta} = \frac{(1 + \beta^2) \cdot (\text{precision} \cdot \text{recall})}{(\beta^2 \cdot \text{precision} + \text{recall})}$$

La medida F equilibra la precisión y el recall.

En algunos problemas, puede que nos interese en una medida F con **más atención puesta en la precisión**, como cuando los falsos positivos son más importante minimizar, pero los falsos negativos siguen siendo importantes. En otros problemas, podríamos estar interesados en una medida F con **más atención puesta en el recall**, como cuando los falsos negativos son más importantes minimizar, pero los falsos positivos siguen siendo importantes. La solución es la medida F_β .

$$F_\beta = \frac{(1 + \beta^2) \cdot (\text{precision} \cdot \text{recall})}{(\beta^2 \cdot \text{precision} + \text{recall})}$$

F0.5-measure ($\beta = 0.5$): Mayor peso en la precisión, menos peso en el recall.

F1-measure ($\beta = 1$): Balance del peso en la precisión y el recall.

F2-measure ($\beta = 2$): Menor peso en la precisión, **más peso en el recall**.


F1 score

Cuando me interesan de igual manera el FP como el FN, utilizo el F1 score.

$$\begin{aligned} F_1 &= \frac{2}{\frac{1}{\text{recall}} \times \frac{1}{\text{precision}}} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}} \\ &= \frac{\text{tp}}{\text{tp} + \frac{1}{2}(\text{fp} + \text{fn})} \end{aligned}$$

Entendamos el F1 score

Supongamos que tenemos una máquina recolectora de frutas, siendo que algunas están maduras y otras no.



Entendamos el F1 score

		True class of apple	
		RIPE	UNRIPE
Model's decision	PICKED	5 (tp)	1 (fp)
	UNPICKED	2 (fn)	2 (tn)

Esta matriz están invertidas las filas y columnas

$$\begin{aligned}\text{precision} &= \frac{\text{tp}}{\text{tp} + \text{fp}} \\ &= \frac{5}{5 + 1} \\ &= 0.83\end{aligned}$$

$$\begin{aligned}\text{recall} &= \frac{\text{tp}}{\text{tp} + \text{fn}} \\ &= \frac{5}{5 + 2} \\ &= 0.71\end{aligned}$$

$$\begin{aligned}F_1 &= 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}} \\ &= 2 \times \frac{0.83 \times 0.71}{0.83 + 0.71} \\ &= 0.77\end{aligned}$$

Precision y Recall se combinan en las curvas de Precision-Recall (curvas PR).

Sensibilidad (Recall) +

- Precision: Curva Precision - Recall
- False Positive Rate: Curva ROC

Resumiendo

Common Name	Other Names	Abbreviation	Definition	Interpretation
True Positive	Hit	TP	True sample labeled True	Correctly labeled True sample
True Negative	Rejection	TN	False sample labeled False	Correctly labeled False sample
False Positive	False Alarm, Type I Error	FP	False sample labeled True	Incorrectly labeled False sample
False Negative	Miss, Type II Error	FN	True sample labeled False	Incorrectly labeled True sample

Resumiendo

Recall	True Positive Rate	TPR	$TP/(TP+FN)$	% of True samples correctly labeled
Specificity	True Negative Rate	SPC, TNR	$TN/(TN+FP)$	% of False samples correctly labeled
Precision	Positive Predictive Value	PPV	$TP/(TP+FP)$	% of samples labeled True that really are True
Accuracy		ACC	$(TP+TN)/(TP+TN+FP+FN)$	Percent of samples correctly labeled
f1 score		f1	$(2*TP)/((2*TP)+FP+FN)$	Approaches 1 as errors decline

Para recordar mejor



Curva ROC y Curva Precision Recall



- Teniendo en mente el eje X y Y de la curva ROC, nuestro foco está en el **TPR**, el **recall** o la **sensibilidad**, y en el **False Positive Rate**, o también **1-Especificidad**.
- mientras que en la **curva Precision-Recall**:
 - Precision
 - Recall (Sensibilidad)

De cierta forma, me esta interesando una sola clase, la clase positiva.

Curva Precision Recall




La curva de Precision-Recall muestra la compensación entre **precisión** y **recall** para diferentes umbrales. Un área alta debajo de la curva representa tanto una alta recall como una alta precisión, donde la alta precisión se relaciona con una tasa baja de falsos positivos y el alto recall se relaciona con una tasa baja de falsos negativos. Los puntajes altos para ambos muestran que el clasificador está arrojando resultados precisos (**alta precisión**), así como también arroja la mayoría de todos los resultados positivos (**alta recall**).

Un sistema con alta recall pero baja precisión arroja muchos resultados, pero la mayoría de las etiquetas previstas son incorrectas en comparación con las etiquetas de entrenamiento.


Un sistema con alta precisión pero poca recall es todo lo contrario, arrojando muy pocos resultados, pero la mayoría de las etiquetas predichas son correctas en comparación con las etiquetas de entrenamiento.

Un sistema **ideal con alta precisión y alta recall** devolverá muchos resultados, con todos los resultados etiquetados correctamente.

Cómo funciona la curva ROC y PR






Curva ROC y PR para clases desbalanceadas



Como se observa la AUC no se ve casi influenciada por el desbalance, lo que nos da una idea que no es una métrica apropiada cuando el desbalance de las clases es severo.

Curva ROC y PR para clases desbalanceadas




<https://paulvanderlaken.com/2019/08/16/roc-auc-precision-and-recall-visually-explained/>

Curva ROC y PR

Un gráfico de Precision-Recall simplemente reemplaza el False Positive Rate en el eje X por la Precisión

Con la Precisión en el eje X, los buenos thresholds para clasificar están cercanos a la esquina superior derecha.



Estrategias para elegir la mejor métrica

Strategies to choose the right metric

Choose accuracy

- The cost of FP and FN are roughly equal.
- The benefit of TP and TN are roughly equal.

Choose Precision

- The cost of FP is much higher than a FN.
- The benefit of a TP is much higher than a TN.

Choose recall

- The cost of FN is much higher than a FP.
- The cost of a TN is much higher than a TP.

ROC AUC & Precision – Recall curves

- Use ROC when the dealing with balanced data sets.
- Use precision-recall for imbalanced data sets.

Resumiendo

Métrica	¿Cuándo usarla? (Escenario ideal)	Principal Ventaja
Recall	Cuando el costo de un Falso Negativo es crítico (ej. detectar cáncer o fallas de seguridad).	Asegura capturar la mayor cantidad de casos positivos posibles.
Precisión	Cuando el costo de un Falso Positivo es alto (ej. clasificar un mail importante como Spam o marcar una transacción legal como fraude).	Asegura que lo que el modelo predice como positivo sea realmente positivo.
F1-Score	Cuando tienes clases desbalanceadas y necesitas un equilibrio entre Precisión y Recall.	Es una métrica única y balanceada que no se deja engañar por el desbalance de clases.
AUPRC	Cuando el desbalance de clases es extremo (ej. 1 caso positivo entre 10,000 negativos).	Se enfoca exclusivamente en el desempeño sobre la clase minoritaria.

Métricas técnicas vs métricas de negocio


Es importante no confundir una métrica técnica (como las vistas anteriormente) con una métrica relacionada al negocio (churn rate, CLV).

Las curvas de aprendizaje son gráficos que se utilizan para mostrar el rendimiento de un modelo a medida que aumenta el tamaño del conjunto de entrenamiento. Otra forma en que pueden utilizarse es para mostrar el rendimiento del modelo durante un periodo de tiempo definido. Normalmente las usamos para diagnosticar algoritmos que aprenden de forma incremental a partir de los datos. Funcionan evaluando un modelo en los conjuntos de datos de entrenamiento y validación, y luego graficando el rendimiento medido.

Esto significa que el gráfico mostrará dos resultados diferentes:

- Curva de entrenamiento: La curva calculada a partir de los datos de entrenamiento; se usa para informar qué tan bien está aprendiendo el modelo.
- Curva de validación: La curva calculada a partir de los datos de validación; se usa para informar qué tan bien se está generalizando el modelo a instancias no vistas.


Curvas de aprendizaje



Curva de Entrenamiento (azul): Se mantiene muy cerca de cero. El modelo "recuerda" perfectamente los ejemplos con los que entrenó.

Curva de Validación (naranja): Se mantiene muy alta y lejos de la azul. Hay una brecha (gap) gigante.


Diagnóstico: El modelo es demasiado complejo para los datos actuales o necesita técnicas de regularización. Añadir más datos podría ayudar a cerrar esa brecha gradualmente.



Comportamiento: Ambas curvas convergen (se juntan) muy rápido, pero en un nivel de error muy elevado (alrededor de 10-12 en el eje RMSE).

Diagnóstico: El modelo "no da para más". Por más que añadas miles de datos nuevos, las líneas seguirán planas en ese nivel de error alto.

Solución: Necesitas un modelo más potente (por ejemplo, pasar de una regresión lineal a un bosque aleatorio o una red neuronal) o crear mejores variables de entrada.



Curva de Entrenamiento (azul): El error sube ligeramente a medida que el tamaño del dataset aumenta, lo cual es normal porque es más difícil ajustar perfectamente muchos puntos que pocos.

Curva de Validación (naranja): El error baja de forma constante hasta acercarse a la curva de entrenamiento.



Diagnóstico: La brecha entre ambas es pequeña. El modelo está aprendiendo patrones generales que se aplican tanto a datos conocidos como a nuevos. Convergen en un nivel de error bajo y estable.

*Balanceo de datos
mediante sampling*

Técnicas de upsampling y downsampling

Cuando hay **clases desbalanceadas** en machine learning, hay dos grandes estrategias de **re-muestreo del dataset**:

- **Downsampling (undersampling)**: reducir el número de ejemplos en la clase mayoritaria.
- **Upsampling (oversampling)**: aumentar el número de ejemplos en la clase minoritaria.



Técnicas de upsampling y downsampling

Downsampling / Undersampling

- Random undersampling
- Tomek Links
- Near Miss
- ENN

Upsampling

- Random oversampling
- SMOTE
- ADASYN

<https://towardsdatascience.com/oversampling-and-undersampling-explained-a-visual-guide-with-mini-2d-dataset-1155577d3091/>

Principios del aprendizaje

1. La Navaja de Occam (Occam's Razor)

Este principio establece que, ante dos explicaciones que justifican los datos de igual manera, la más sencilla suele ser la correcta.

- **En el contexto del aprendizaje:** Si dos modelos logran el mismo error dentro de la muestra (E_{in}), el modelo con menor complejidad (menor dimensión VC) tendrá más probabilidades de generalizar mejor fuera de la muestra (E_{out}).
- **La lección:** La simplicidad no es solo una cuestión estética; es una protección matemática contra el sobreajuste (overfitting).

El modelo más simple que pueda ser ajustado,
es el más factible.

Si tuviéramos para elegir entre un modelo simple y un modelo complejo, debo elegir siempre el modelo más simple.

Navaja de Occam y Principio de Parsimonia

Simpler models are more accurate. This belief is sometimes equated with Occam's razor, but the razor only says that simpler explanations are preferable, not why. They're preferable because they're easier to understand, remember, and reason with. Sometimes the simplest hypothesis consistent with the data is less accurate for prediction than a more complicated one. Some of the most powerful learning algorithms output models that seem gratuitously elaborate — sometimes even continuing to add to them after they've perfectly fit the data — but that's how they beat the less powerful ones.

Navaja de Occam y Principio de Parsimonia

- *Principio de Parsimonia*

El **principio de parsimonia** es una regla general que sugiere elegir explicaciones o modelos con la menor cantidad de supuestos y componentes innecesarios. Este principio se puede aplicar en distintos contextos, desde la filosofía hasta las ciencias empíricas, y no es específico de ninguna disciplina en particular.

- *Navaja de Occam*

La **Navaja de Occam** es una manifestación práctica del principio de parsimonia. Mientras que el principio de parsimonia es una idea general de economía conceptual, la Navaja de Occam se utiliza como una herramienta para la toma de decisiones, orientando a los científicos, filósofos e investigadores a preferir hipótesis y teorías simples hasta que haya pruebas que justifiquen complejizar la explicación.

2. Sesgo de Muestreo (Sampling Bias)

Este principio advierte que si los datos de entrenamiento no son representativos de los datos que el modelo encontrará en el futuro, el aprendizaje fallará.

- **La regla de oro:** "Si los datos se recolectan con un sesgo, el aprendizaje aprenderá ese sesgo".
- **Ejemplo:** Si se entrena un modelo para predecir el éxito académico usando sólo datos de una universidad privada de élite, el modelo no funcionará correctamente para la población general, porque la muestra no representa la distribución real de entrada ($P(x)$)

Si los datos tienen un sesgo (bias), el resultado de aplicar un algoritmo tendrá ese mismo bias.

Bias en el muestreo



Un buen ejemplo de sampling bias fueron las elecciones presidenciales de EEUU de 1948 entre Truman y Dewey. Un diario llevo a cabo una encuesta para preguntar a quién habían votado. La encuesta indicaba que Dewey ganaría las elecciones. En 1948, los teléfonos eran caros y sólo una élite contaba con ellos.

La distribución de las encuestas no coincidía con la distribución de los votantes de la elección. Ambas distribuciones deben coincidir.

If the data is sampled in a biased way, learning will produce a similarly biased outcome.

**MUY
IMPORTANTE**

Applying this principle, we should make sure that the training and testing distributions are the same; if not, our results may be invalid, or, at the very least, require careful interpretation.


If you recall, the VC analysis made very few assumptions, but one assumption it did make was that the data set $\mathcal{D}$ is generated from the same distribution that the final hypothesis g is tested on. In practice, we may encounter data sets that were not generated under those ideal conditions. There are some techniques in statistics and in learning to compensate for the 'mismatch' between training and testing, but not in cases where $\mathcal{D}$ was generated with the exclusion of certain parts of the input space, such as the exclusion of households with no telephones in the above example. There is nothing that can be done when this happens, other than to admit that the result will not be reliable. Statistical bounds like Hoeffding and VC require a match between the training and testing distributions.

3. "Data Snooping" (Fisgoneo de Datos)

Este es el principio más sutil y peligroso. Ocurre cuando el investigador toma decisiones sobre el modelo basándose en haber "mirado" los datos de antemano.

- **Cómo ocurre:** Si eliges una transformación de características o una arquitectura de red neuronal porque "viste" que funcionaba bien en tus datos de prueba, estás contaminando el proceso.
- **La consecuencia:** Los resultados de validación serán optimistas y falsos, ya que el modelo ya "conoce" indirectamente la respuesta. El libro enfatiza que "si uno ve los datos, el E_{in} ya no es una guía confiable para el E_{out} ".

El set de datos de testeo no debe usarse nunca durante el entrenamiento, ya que esto arrojará resultados más optimistas que los esperados.



Ganancias con data leakage

Ganancias sin data leakage

1. Investigar los métodos de downsampling y upsampling. Cada alumno deberá interiorizarse con 1 método de downsampling y upsampling.
2. Dataset: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>
3. Luego con ese dataset balanceado en cuanto a las categorías de estudio, deberá aplicarse un método de clasificación (regresión logística y SVM) para ver el impacto del balanceo en el modelo.
4. Sacar conclusiones.
5. Dos alumnos NO PUEDEN realizar el mismo método de downsampling y upsampling.
6. Debe trabajarse en google colab y entregar el archivo .ipynb final + explicación de downsampling + upsampling (ppt)
7. Una breve exposición oral para explicar efectos del balanceo.
8. Fecha de entrega: 22/04/2026 Exposición oral: 24/04/2026

Bibliografía

Abu-Mostafa, Y. Learning from data.

Brownlee, J. Imbalanced classification with Python.

<https://www.datacamp.com/es/blog/classification-machine-learning>

<https://www.datacamp.com/tutorial/f1-score>

<https://www.datacamp.com/tutorial/precision-recall-curve-tutorial>

<https://www.datacamp.com/tutorial/tutorial-learning-curves>

<https://www.datacamp.com/tutorial/precision-vs-recall>

<https://www.datacamp.com/tutorial/sensitivity-specificity-complete-guide>

<https://www.datacamp.com/tutorial/tutorial-learning-curves>

<https://www.datacamp.com/es/tutorial/precision-recall-curve-tutorial>

<https://medium.com/@abdallahashraf90x/oversampling-for-better-machine-learning-with-imbalanced-data-68f9b5ac2696>