

Unidad 3

Fundamentos: modelo logit, función sigmoide, probabilidad y clasificación binaria. Interpretación de coeficientes y *odds ratios*. Regularización aplicada a regresión logística. Ajuste de umbrales: curvas ROC, Precision–Recall y selección del punto óptimo según el tipo de error prioritario. Aplicaciones espaciales

Regresión Logística

La regresión logística es una técnica de análisis estadístico fundamental, diseñada para modelar la relación entre una variable dependiente de naturaleza cualitativa y dicotómica (binaria) y una o más variables explicativas independientes, que pueden ser tanto cualitativas como cuantitativas. A diferencia de la regresión lineal, que se utiliza para predecir valores continuos, la regresión logística se enfoca en estimar la probabilidad de que una observación pertenezca a una categoría específica o que un evento de interés ocurra. Esta probabilidad, por su propia definición, se restringe inherentemente al rango entre 0 y 1.

La utilidad central de la regresión logística radica en su capacidad para actuar como un clasificador probabilístico. Mientras que otros algoritmos de clasificación pueden simplemente asignar una etiqueta binaria (por ejemplo, "sí" o "no"), la regresión logística va un paso más allá al proporcionar una probabilidad asociada a esa clasificación. Esta distinción es crucial porque la obtención de un valor probabilístico (entre 0 y 1) permite cuantificar la incertidumbre de la predicción, lo que es invaluable para la evaluación de riesgos y la toma de decisiones informadas.

Regresión logística





Figure 4.6 Summary of how logistic regression models predict class membership. Data is converted into log odds (logits), which are converted into odds and then into the probability of belonging to the “positive” class. Cases are assigned to the positive class if their probability exceeds a threshold probability (0.5 by default).

La regresión lineal está intrínsecamente diseñada para modelar variables dependientes de naturaleza continua, como el salario o el consumo de electricidad. Cuando se intenta aplicar este modelo a problemas de clasificación binaria, por ejemplo, codificando las dos clases posibles como 0 y 1, surge una limitación fundamental. La regresión lineal puede generar predicciones que caen fuera del rango lógico de una probabilidad, es decir, valores menores que 0 o mayores que 1. Esta incompatibilidad del rango de salida es una contradicción matemática inherente, ya que las probabilidades, por definición, deben estar siempre entre 0 y 1.

Limitaciones de la regresión lineal




Esta limitación no es trivial; es la razón causal principal para el desarrollo y la adopción de la regresión logística. Un modelo lineal, al trazar una línea recta, no puede establecer un límite de decisión claro y robusto entre las clases, ya que trata las etiquetas de clase como valores numéricos continuos. Esto puede llevar a clasificaciones erróneas, especialmente cuando los datos no son perfectamente separables linealmente.

Función logística o sigmoide

La función logística, también conocida como función sigmoide, es el componente matemático central y distintivo de la regresión logística. Su forma característica es una curva en forma de "S". Su propósito fundamental es transformar cualquier valor de entrada, que puede ser un número real dentro de un rango ilimitado $(-\infty, +\infty)$, en un valor comprendido estrictamente entre 0 y 1.

$$f(x) = \frac{1}{1 + e^{-x}},$$




Función logística o sigmoide

ecuación de regresión lineal

$$\hat{y} = b_1 \cdot x_1 + b_2 \cdot x_2 + \dots + b_k \cdot x_k + a$$

$$f(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-(b_1 \cdot x_1 + \dots + b_k \cdot x_k + a)}}$$

Función sigmoidea




El papel de esta función es crucial: al aplicar la función sigmoide a la combinación lineal de las variables independientes, la regresión logística asegura que la salida del modelo se interprete como una probabilidad, resolviendo así la limitación de la regresión lineal de producir valores fuera del rango . La forma de "S" de la función sigmoide no es arbitraria; es la que permite la transición suave de una combinación lineal ilimitada a una probabilidad acotada. Esta forma implica que pequeños cambios en el predictor lineal tienen un impacto más significativo en la probabilidad cuando esta se encuentra cerca del 0.5 (el punto de inflexión), mientras que el impacto disminuye a medida que la probabilidad se acerca a 0 o 1.

$$P(y = 1|x_1, \dots, x_n) = \frac{1}{1 + e^{-(b_1 \cdot x_1 + \dots + b_k \cdot x_k + a)}}$$

1. La salida cruda (Log-Odds)

Si aplicas la ecuación lineal del modelo $\beta_0 + \beta_1 x$, el resultado **no es una probabilidad**. Es el **Logit**, también conocido como **log-odds** (el logaritmo natural del momio).

- Este valor puede ser cualquier número real, desde $-\infty$ hasta $+\infty$
- No es intuitivo para los humanos, pero es lo que el modelo calcula internamente.




2. La transformación (Probabilidad)

Para obtener una probabilidad, debemos pasar ese resultado por la **función sigmoide** (o función logística).

$$f(x) = \frac{1}{1 + e^{-x}},$$

Una vez aplicada esta función, la salida sí es un valor entre **0 y 1**, el cual interpretamos como la **probabilidad** de que la observación pertenezca a la clase positiva.



3. La salida final (Clasificación)

Si estamos usando el modelo para clasificar (por ejemplo, en un entorno de Machine Learning con **Scikit-Learn**), la salida final suele ser una **clase binaria (0 o 1)**. Para llegar ahí, se aplica un **umbral** (threshold), que por defecto suele ser 0.5.




Figure 4.3 Modeling the data with the logistic function. The S-shaped curve represents the logistic function fitted to the data. The center of the curve passes through the mean of copper content and maps it between 0 and 1.




Figure 4.8 The process of classifying new paintings. The predictor variable values of three paintings are converted into log odds based on the learned model parameters (intercept and slopes). The log odds are converted into probabilities (p), and if $p > 0.5$, the case is classified as the “positive” class.

Regresión logística en estadística

Objetivo: **Explicar y comprender** la relación entre una variable dependiente binaria (por ejemplo, éxito/fracaso, sí/no) y un conjunto de variables independientes.

Fundamento: Es un **modelo paramétrico**: se asume que la relación entre las variables sigue una forma funcional específica (la función logística).

Lo que se busca es **inferir** —es decir, entender el efecto de cada predictor sobre la probabilidad del evento.

Se interpretan los **coeficientes (betas)**:

Cada β indica el cambio en el *log-odds* del evento por unidad de cambio en el predictor.

Se pueden transformar en **odds ratios**, que indican multiplicadores de probabilidad.

Supuestos del modelo (independencia, no multicolinealidad, linealidad en el logit, tamaño de muestra suficiente).

Pruebas de significancia: Wald, razón de verosimilitudes, etc.

Bondad de ajuste: Hosmer-Lemeshow, pseudo- R^2 .

Intervalos de confianza para los coeficientes.

La regresión logística en estadística se usa como una herramienta de inferencia y explicación causal o asociativa.

Supuestos de la regresión logística

1. Naturaleza de la Variable Dependiente

La variable de respuesta debe ser **binaria o dicotómica** para una regresión logística simple (ej: Sí/No, Éxito/Fracaso, 0/1). Si tiene más de dos categorías, se debe usar una regresión logística multinomial.

2. Independencia de las Observaciones

Las mediciones no deben estar relacionadas entre sí. Esto significa que los datos no deben provenir de medidas repetidas o de un diseño de estudio donde las respuestas de un sujeto influyan en otro. En términos técnicos: los residuos deben ser independientes.

3. Linealidad del Logit (Log-Odds)

Este es uno de los supuestos más importantes y a veces el más incomprendido. La regresión logística no asume que la relación entre X e Y sea lineal, sino que existe una **relación lineal entre las variables independientes y el logaritmo de las probabilidades** (logit) de la variable dependiente. Si esta relación no es lineal, el modelo perderá mucho poder predictivo.

4. Ausencia de Multicolinealidad

Las variables independientes no deben estar altamente correlacionadas entre sí. Si dos variables explican lo mismo (ej: "Ingresos mensuales" e "Ingresos anuales"), el modelo tendrá dificultades para determinar el efecto individual de cada una, aumentando el error estándar de los coeficientes.

5. Tamaño de la Muestra (Gran cantidad de datos)

La regresión logística requiere muestras grandes para que las estimaciones de máxima verosimilitud sean estables. Una regla empírica común es tener al menos **10 a 20 casos del evento menos frecuente** por cada variable independiente incluida en el modelo.

6. Ausencia de Outliers Extremos

Aunque la logística es más robusta que la lineal, los valores atípicos extremos en las variables independientes pueden influir desproporcionadamente en las estimaciones y sesgar los resultados

- Regresión logística binomial: Este tipo se utiliza cuando la **variable dependiente** tiene solo **dos categorías** posibles. Los ejemplos incluyen Sí/No, Aprobado/Reprobado o 0/1. Es la forma más común de regresión logística y se emplea para problemas de clasificación binaria
- Regresión logística multinomial: Se utiliza cuando la **variable dependiente** tiene **tres o más categorías** posibles que **no están ordenadas**. Por ejemplo, clasificar animales en categorías como "gato", "perro" u "oveja". Extiende la regresión logística binaria para manejar múltiples clases.
- Regresión logística ordinal: Este tipo se aplica cuando la **variable dependiente** tiene **tres o más categorías** con un **orden o clasificación natural**. Los ejemplos incluyen calificaciones como "baja", "media" y "alta". Tiene en cuenta el orden de las categorías al modelar.

Types of Logistic Regression

Binomial

Two classes (0 or 1)




Multinomial

More than two unordered classes (cat, dog, sheep)



Ordinal

More than two ordered classes (low, medium, high)



Función de pérdida en Regresión logística binaria

Log-Loss (Entropía Cruzada Binaria)

En el caso binario (0 o 1), queremos que el modelo asigne una probabilidad alta al evento real. Si la etiqueta real es $y=1$, la pérdida es menor cuanto más cerca esté la predicción $\hat{y}$ de 1.

La fórmula de la **Log-Loss** para una observación es:

$$L(y, \hat{y}) = - [y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$

¿**Cómo funciona?** Si $y=1$, el segundo término desaparece y solo penalizamos según el logaritmo de la predicción. Si el modelo predice 0.1 cuando debería ser 1, la penalización es enorme (tiende a infinito).

Función de pérdida en Regresión logística multiclase

Cuando tenemos más de dos categorías independientes (por ejemplo, clasificar tipos de cobertura de suelo: bosque, agua, urbano), la regresión logística suele utilizar la función **Softmax** en la última capa para que todas las probabilidades sumen 1.

La función de pérdida aquí se llama **Entropía Cruzada Categórica**:

$$L = - \sum y_i \log (\hat{y}_i)$$


La función Softmax es el componente matemático esencial que generaliza la regresión logística para problemas de **clasificación multiclase**. Su propósito principal es transformar un vector de números reales, conocidos como *logits* (la salida directa de la capa final de un modelo), en una **distribución de probabilidad**.

Propósito y Definición:

- **Normalización:** Softmax asegura que cada valor de salida esté en el rango $[0, 1]$ y que la suma de todas las probabilidades de las clases sea exactamente 1.
- **Interpretación:** La salida de Softmax se interpreta como la probabilidad de que una observación pertenezca a cada una de las K categorías posibles. El valor más alto indica la clase predicha.¹
- **Proceso Clave:** Aplica la función exponencial a cada logit y luego divide el resultado por la suma de todas las exponenciales. Este uso de la exponencial **enfatisa la diferencia** entre los valores, haciendo que la probabilidad de la clase con el logit más alto se acerque a 1, mientras que las demás se acercan a 0.

Interpretación de coeficientes

Ecuación del modelo de regresión logística



The diagram shows the logistic regression equation with several annotations. The equation is $\ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_i x_i$. The left side, $\ln\left(\frac{p}{1-p}\right)$, is enclosed in a red rectangle and labeled "función de log-odds" with an arrow. Inside this rectangle, the fraction $\frac{p}{1-p}$ is enclosed in a smaller red rectangle and labeled "momios (log-odds)" with an arrow. The right side of the equation is enclosed in a light gray rectangle. The term β_0 is circled in red and labeled "intercept" with an arrow. The terms $\beta_1 x_1$, $\beta_2 x_2$, and $\beta_i x_i$ are each circled in red. A bracket labeled "coeficientes del modelo" with an arrow points to these three circled terms.

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_i x_i$$

función de log-odds

momios (log-odds)

intercept

coeficientes del modelo

Relación con la Probabilidad: El *momio* se define matemáticamente como la razón de la probabilidad de que un evento ocurra P frente a la probabilidad de que no ocurra $(1-P)$

$$\frac{p}{1 - p}$$

Función Logit (Log-Odds): Es fundamental mencionar la conexión con el logaritmo de los momios (log-odds o *logit*). La regresión logística modela la relación lineal entre las variables predictoras y el log-odds.

$$\ln\left(\frac{p}{1 - p}\right)$$

Esto se resume en que:

El logaritmo de las *chances* (momios) se comporta de forma lineal.

Interpretación de Coeficientes (β): En el contexto de la regresión logística, los coeficientes (β) se interpretan en términos del log-odds:

- El coeficiente β representa el cambio en el logaritmo de la probabilidad (log-odds) por cada unidad que aumenta la variable predictora X.
- Estos coeficientes (betas) se pueden transformar en **Odds Ratios** (razón de momios), los cuales indican multiplicadores de probabilidad, lo que facilita su interpretación.
- Si β es positivo, al aumentar X, aumenta la probabilidad del evento. Si β es negativo, la probabilidad del evento disminuye.

Función sigmoide

$$\begin{aligned} p &= \frac{1}{1 + e^{-(a_0 + a_1 x_1 + \dots)}} \\ \Rightarrow \frac{1}{p} &= 1 + e^{-(a_0 + a_1 x_1 + \dots)} \\ \Rightarrow \log\left(\frac{1}{p} - 1\right) &= -(a_0 + a_1 x_1 + \dots) \\ \Rightarrow \log\left(\frac{p}{1 - p}\right) &= a_0 + a_1 x_1 + \dots \end{aligned}$$

Función logit

Linealidad: Podemos decir que el logaritmo de las chances se comporta de forma lineal. Esto permite que usemos algoritmos similares a los de la regresión lineal para resolver problemas de clasificación.

Interpretación: Esta ecuación es la que nos permite decir: "Si subo X en una unidad, el log-odds sube en a_1 ".

Logaritmo de la probabilidad (log-odds)

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_i x_i$$

$$\text{logit}(Y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_i x_i$$

El coeficiente **β** representa el cambio en el **logaritmo de la probabilidad (log-odds)** por cada unidad que aumenta la variable X.

- **Si β es positivo:** Al aumentar X, aumenta la probabilidad del evento.
- **Si β es negativo:** Al aumentar X, disminuye la probabilidad del evento.
- **Si β es cero:** La variable no tiene efecto sobre la probabilidad.

Diabetes dataset

Variables	Descripción
Pregnancies	Número de veces que la paciente ha estado embarazada.
Glucose	Concentración de glucosa plasmática a las 2 horas en una prueba de tolerancia oral a la glucosa.
BloodPressure	Presión arterial diastólica (mm Hg).
SkinThickness	Grosor del pliegue cutáneo del tríceps (mm).
Insulin	Insulina sérica de 2 horas (U/ml).
BMI	Índice de masa corporal (peso en \$kg / (altura en m ²).
DiabetesPedigreeFunction	Una función que puntúa la probabilidad de diabetes basada en los antecedentes familiares.
Age	Edad en años.

Modelo de regresión logística

Pregnancies	0.064546
Glucose	0.034106
BloodPressure	-0.013889
SkinThickness	0.003149
Insulin	-0.001816
BMI	0.102610
DiabetesPedigreeFunction	0.694508
Age	0.037087
Intercept	-9.035903

$$z = -9.0359 + 0.0645 \text{ Pregnancies} + 0.0341 \text{ Glucose} - 0.0139 \text{ BloodPressure} + 0.0031 \text{ SkinThickness} - 0.0018 \text{ Insulin} + 0.1026 \text{ BMI} + 0.6945 \text{ DPF} + 0.0371 \text{ Age}$$

Evaluación de la regresión logística

- Evaluación del modelo de regresión logística (significancia estadística)
 - Likelihood ratio test
 - Test de Hosmer - Lemeshow
- Evaluación de los coeficientes del modelo (significancia estadística)
 - Prueba de Wald
- Varianza explicada por el modelo
 - PseudoR²
- Selección de modelos
 - AIC / BIC

Likelihood ratio test

El test se basa en el concepto de **Verosimilitud (Likelihood)**, que mide qué tan probable es que los datos observados hayan sido generados por el modelo. Un modelo con una verosimilitud más alta se considera un mejor ajuste. La prueba compara:

1. **Modelo Nulo (L0)**: El modelo más simple, que generalmente incluye solo el intercepto (la media). Asume que las variables predictoras que se están probando no tienen efecto.
2. **Modelo Completo (L1)**: El modelo que incluye el intercepto **más** las variables predictoras de interés.

H_0 : El Modelo Completo **no** es significativamente mejor que el Modelo Nulo. Las variables predictoras añadidas no tienen un efecto significativo en la predicción.

H_1 : El Modelo Completo **es** significativamente mejor que el Modelo Nulo. Al menos una de las variables predictoras añadidas tiene un efecto significativo.

Si el **p-valor** > 0.05 , no se rechaza $H_0 \rightarrow$ el modelo complejo no es significativamente mejor

Si el **p-valor** < 0.05 , se rechaza $H_0 \rightarrow$ significa que el conjunto de variables añadidas es **significativo** y el Modelo Completo es preferible.

Test de Hosmer – Lemeshow

Es la más utilizada para evaluar la bondad de ajuste en regresión logística.

Fundamento:

- Divide las probabilidades predichas por el modelo en **grupos (por ejemplo, 10 deciles)**.
- Compara los valores **observados** vs **esperados** de la variable dependiente (0/1) dentro de cada grupo.

H_0 : El modelo se ajusta bien a los datos (no hay diferencia significativa entre observados y esperados).

H_1 : El modelo no se ajusta bien.

Si el **p-valor** > 0.05 , no se rechaza $H_0 \rightarrow$ el modelo tiene un **buen ajuste**.

Si el **p-valor** < 0.05 , se rechaza $H_0 \rightarrow$ el modelo **no se ajusta bien**.

¿Contribuye realmente esta variable predictora (independiente) al modelo?

Fundamento:

Determinar si el coeficiente β estimado para una variable predictora en particular es significativamente diferente de cero.

Si un coeficiente es igual a cero, significa que esa variable no tiene ningún efecto sobre la probabilidad del evento (el *log-odds*), por lo que es inútil para el modelo.

H_0 : El coeficiente es cero. La variable no es significativa.

H_1 : El coeficiente no es cero. La variable es significativa.

Si el **p-valor** > 0.05 , no se rechaza $H_0 \rightarrow$ la variable predictora es estadísticamente significativa.

Si el **p-valor** < 0.05 , se rechaza $H_0 \rightarrow$ la variable es significativa.

Pseudo-R²

Existen varias versiones de Pseudo-R²:

- Cox & Snell R²
- Nagelkerke / Cragg & Uhler R²
- McFadden R²

$$R^2_{\text{Cox\&Snell}} = 1 - \frac{(L_{\text{null}})^{2/n}}{(L_{\text{mod}})^{2/n}}$$

$$R^2_{\text{Nagelkerke}} = \frac{R^2_{\text{Cox\&Snell}}}{1 - (L_{\text{null}})^{2/n}}$$

$$R^2_{\text{McFadden}} = 1 - \frac{\ln(L_{\text{mod}})}{\ln(L_{\text{null}})}$$

R^2_{McFadden} : Es el estándar en la investigación científica. Compara la verosimilitud del modelo con predictores frente a un modelo básico (nulo).

$R^2_{\text{Cox\&Snell}}$: Se basa en la razón de verosimilitud (L) y el tamaño de la muestra (n).

$R^2_{\text{Nagelkerke}}$: Es una versión "normalizada" del índice de Cox & Snell. Se divide el valor obtenido por el máximo teórico posible (R^2_{max}).

Pseudo- R^2

Pseudo R^2	Valores de buen ajuste	Interpretación
McFadden R^2	Se considera que un valor entre 0.2 y 0.4 indica un ajuste excelente .	Representa el nivel de mejora en la verosimilitud que aportan tus variables respecto a un modelo que solo usa la constante (el promedio). No se interpreta como "porcentaje de varianza explicada" como en la regresión lineal.
Cox & Snell R^2	Es difícil de estandarizar porque su valor máximo suele ser menor a 1 (depende de las probabilidades marginales de los datos).	Intenta imitar el R^2 de los mínimos cuadrados, pero su limitación técnica al no llegar a 1 lo hace menos popular que los otros dos.
Nagelkerke / Cragg & Uhler R^2	Al estar escalado de 0 a 1 , se buscan valores lo más cercanos a 1 posible. Generalmente, valores por encima de 0.5 o 0.6 se consideran muy buenos en contextos prácticos.	Es el más "amigable" para reportar, ya que permite decir qué tan cerca está el modelo del "ajuste perfecto" en una escala de 0 a 100%.

Regresión logística en aprendizaje automático

Regresión logística en aprendizaje automático

Objetivo: **Predecir** correctamente la clase de nuevas observaciones (clasificación binaria).


Fundamento: Se considera un **modelo de clasificación supervisada**. No interesa tanto la interpretación de los coeficientes, sino **la capacidad predictiva**. Se optimiza el **error de clasificación** o la **log-loss** (función de pérdida). Se utilizan **técnicas de regularización** (L1, L2) para evitar el sobreajuste.

En ML: Puede competir con otros modelos (árboles, SVM, redes neuronales). Se prioriza la **generalización** a datos nuevos, más que la interpretación.

La regresión logística en machine learning se usa como un algoritmo de clasificación predictiva, no tanto para interpretar relaciones.

Umbral y matriz de confusión

i	features	label
i_1	$(f_1, \dots, f_n)$	P
...		P
...		N
...		N
...		P
...		P
...		N
i_n		P



Predicción
del modelo

1

1

0

0

0

0

0

0

Sólo estas
muestras serán
clasificadas
como P


Matriz de confusión

Predicción

True label	P	N	Tot
P			5
N			3
	2	6	8

Umbral y matriz de confusión

i	features	label
i_1	$(f_1, \dots, f_n)$	P
...		P
...		N
...		N
...		P
...		P
...		N
i_n		P



Predicción
del modelo

1
1
0
0
0
0
0
0

Sólo estas
muestras serán
clasificadas
como P


Matriz de confusión

Predicción

True label	P	N	Tot
P	2	3	5
N	0	3	3
	2	6	8

Umbral y matriz de confusión

i	features	label
i_1	$(f_1, \dots, f_n)$	P
...		P
...		N
...		N
...		P
...		P
...		N
i_n		P



Score
0.98
0.9
0.73
0.57
0.45
0.37
0.14
0.03

Predicción
del modelo

1
1
1
1
0
0
0
0

Sólo estas
muestras serán
clasificadas
como P

Matriz de confusión


Predicción

True label	P	N	Tot
P	2	3	5
N	2	1	3
	4	4	8

Regresión logística & Curva ROC


13

Likewise, for each threshold that increases the number of **Positive** classifications (in this example, that means classifying a person as someone who **Loves Troll 2**), we calculate the **True Positive Rate** and **False Positive Rate** until everyone is classified as **Positive**.




	Predicted	
	Yes	No
Actual Yes	3	2
Actual No	0	4

Threshold = 0.95








	Predicted	
	Yes	No
Actual Yes	3	2
Actual No	1	3

Threshold = 0.87



True Positive Rate
(or Sensitivity
or Recall)

False Positive Rate
(or 1 - Specificity)



Esto nos recuerda que la curva ROC es independiente del umbral seleccionado (ya que la misma curva ROC incluye todas las posibilidades de corte)

Es válido todo lo visto para clasificadores binarios y multiclase.

- MATRIZ DE CONFUSIÓN Y MÉTRICAS DERIVADAS
- CURVAS ROC
- CURVAS PRECISION - RECALL

Hiperparámetros

penalty (Penalización) - define el "Cómo" (Cualitativo)

Define el tipo de regularización que se aplicará al modelo. La regularización ayuda a simplificar el modelo penalizando los coeficientes grandes.

- **'l2'**: Es el valor por defecto. Añade una penalización igual al cuadrado de la magnitud de los coeficientes.
- **'l1'**: Añade una penalización igual al valor absoluto de los coeficientes. Puede ser útil para la selección de características, ya que puede llevar algunos coeficientes a cero.
- **'elasticnet'**: Una combinación de L1 y L2 (requiere configurar **l1_ratio**).
- **None**: No se aplica ninguna penalización.

C (Inversa de la fuerza de regularización) define el "Cuánto" (Cuantitativo)

El parámetro **C** es la **inversa de la fuerza de regularización** ($C = 1/\lambda$). Si **penalty** es el tipo de freno, **C** es la presión que ejerces sobre él.

- **C pequeño (ej. 0.01):** La regularización es muy fuerte. El modelo es "obligado" a tener coeficientes muy pequeños, lo que simplifica el modelo y reduce el riesgo de sobreajuste (*overfitting*), pero puede causar subajuste (*underfitting*).
- **C grande (ej. 1000):** La regularización es débil. El modelo tiene más libertad para ajustarse a los datos de entrenamiento. Si es demasiado grande, el modelo podría memorizar los datos y fallar con datos nuevos.

solver (Algoritmo de optimización)

Determina qué algoritmo se utiliza para encontrar los pesos óptimos:

- **'lbfgs'**: (Por defecto) Bueno para conjuntos de datos pequeños y medianos. Soporta penalización L2 o ninguna.
- **'liblinear'**: Recomendado para conjuntos de datos pequeños. Es el único que soporta penalización L1 y solo funciona para clasificación uno-contra-el-resto (OvR).
- **'saga'**: Ideal para conjuntos de datos muy grandes y soporta todas las penalizaciones (L1, L2, ElasticNet).
- **'newton-cg'** y **'sag'**: Adecuados para datos grandes y multiclase.

random_state

Se utiliza para asegurar la reproducibilidad de los resultados cuando se utilizan los solvers **'sag'**, **'saga'** o **'liblinear'**, ya que estos tienen componentes aleatorios.

multi_class (Comportamiento multiclase)

- **'ovr' (One-vs-Rest)**: Ajusta un clasificador binario para cada clase.
- **'multinomial'**: Se utiliza si el problema tiene más de dos clases (la pérdida minimizada es la pérdida multinomial). No disponible si el solver es **'liblinear'**.

class_weight (Peso de las clases)

Útil cuando tienes un conjunto de datos desbalanceado.

- **None**: Todas las clases tienen peso 1.
- **'balanced'**: Ajusta automáticamente los pesos de forma inversamente proporcional a las frecuencias de las clases en los datos de entrada.

Resumiendo

Hiperparámetro	Breve Definición	Relación con el Overfitting
penalty	Tipo de regularización aplicada (l1, l2, elasticnet).	L1 ayuda a reducir el overfitting eliminando variables irrelevantes (las hace 0).
C	Inversa de la fuerza de regularización ($1/\lambda$).	Si aumenta C , aumenta el riesgo de overfitting (menos regularización).
solver	Algoritmo matemático para optimizar los pesos.	No afecta directamente al overfitting, pero algunos convergen mejor en datos complejos.

Resumiendo

Hiperparámetro	Breve Definición	Relación con el Overfitting
max_iter	Número máximo de iteraciones para que el modelo converja.	Si es muy bajo, el modelo no aprende bien (underfitting). No suele causar overfitting.
class_weight	Ajusta el peso de las clases (útil si están desbalanceadas).	Ayuda a que el modelo no se "sobreajuste" solo a la clase mayoritaria.
l1_ratio	Balance entre L1 y L2 (solo si usas penalty='elasticnet').	Un valor cercano a 0 actúa como L2; cercano a 1 actúa como L1 (más selectivo).

Ventajas y desventajas de la regresión logística

Ventajas

- La regresión logística es más fácil de implementar, interpretar y muy eficiente de entrenar.
- No hace suposiciones sobre distribuciones de clases en el espacio de características.
- Puede extenderse fácilmente a múltiples clases.
- Puede interpretar los coeficientes del modelo como indicadores de la importancia de una característica.

Desventajas

- Los problemas no lineales no se pueden resolver con la regresión logística porque tiene una superficie de decisión lineal. Rara vez se encuentran datos linealmente separables en escenarios del mundo real.
- Es difícil obtener relaciones complejas mediante la regresión logística. Algoritmos más potentes y compactos, como las redes neuronales, pueden superar fácilmente a este algoritmo.
- Si el número de observaciones es menor que el número de características, no se debe utilizar la regresión logística; de lo contrario, puede provocar un sobreajuste.

Aplicaciones Espaciales

Geographically weighted logistic regression


Extensión de la regresión logística que permite analizar cómo las relaciones entre variables cambian en el espacio geográfico. A diferencia de la regresión logística tradicional, que asume que los efectos de las variables son constantes en todas las áreas, la GWLR ajusta el modelo de manera local para diferentes ubicaciones geográficas, ponderando los datos de acuerdo con la distancia.

Esto permite explorar cómo las relaciones entre las variables pueden variar en diferentes regiones.

Geographically weighted logistic regression

Highlights del paper

- Existence of spatial variation in the relationship between mode choice and demographic and socioeconomic variables.
- Built environment variables were found to be weak predictors of travel mode choice.
- Occurrence of spatial mismatch between demographic and socioeconomic attributes.




Geographically weighted logistic regression

Application of geographically weighted logistic regression (GWLR) model for exploring spatially heterogeneous relationships.

Fatal crashes were less likely to occur when medians exist on roads and around institutional land use.

The likelihood of fatal crashes increased on straight and flat roads and at locations with more bus stops.



Geographically weighted elastic net logistic regression

Patrones de voto (Voting patterns)





Fig. 1 The election data and socio-economic attributes from the US population census

Remuestreo Espacial



- La división aleatoria de datos espaciales puede conducir a puntos de entrenamiento que son vecinos en el espacio con puntos de prueba. Debido a la autocorrelación espacial, los conjuntos de datos de prueba y entrenamiento no serían independientes en este escenario, con la consecuencia de que CV (cross-validation) no detecta un posible sobreajuste.
- Spatial CV tiene en cuenta esto y trata de evitar el sobreajuste (overfitting).



Remuestreo simple vs remuestreo espacial



Remuestreo espacial



Para implementar en R con
tidymodels:

<https://juliasilge.com/blog/map-challenge/>





La idea es variar los folds según
un criterio espacial, en vez de
hacerlo de forma aleatoria.

Fuente: <https://geocompr.robinlovelace.net/spatial-cv.html>

Remuestreo espacial para entender sequías en Texas


Datos:

<https://github.com/rfordatascience/tidyuesday/tree/master/data/2022/2022-06-14>




Fuente: <https://juliasilge.com/blog/drought-in-tx/>


Locally varying geostatistical machine learning for spatial prediction




(a) RK



(b) RFSP



(c) RFSI



(d) LVGRF

- La regresión logística a diferencia de la regresión lineal la utilizamos para predecir una clase (1,0) o multiclase.
- Los coeficientes del modelo nos ayudan a interpretar como las variables influyen en el modelo.
- Los tests estadísticos correspondientes nos ayudan a conocer la bondad del modelo.
- En el aprendizaje automático nos interesa sin embargo, conocer la capacidad predictiva del modelo.

Característica	Enfoque Estadístico (Inferencia)	Enfoque Machine Learning (Predicción)
Objetivo Principal	Explicar: Entender la relación y significancia entre variables.	Predecir: Maximizar la exactitud de la clasificación en datos nuevos.
Supuestos	Muy estrictos (Independencia, ausencia de multicolinealidad).	Flexibles; el foco está en el rendimiento del algoritmo.
Tratamiento de Datos	Se usa el dataset completo para ajustar el modelo.	Se divide en Train, Test y Validation sets .
Interpretación	Basada en Odds Ratios y p-valores (¿Es X significativa?).	Basada en métricas de error y curvas (ROC, Precision-Recall).
Complejidad	Se prefieren modelos simples y parsimoniosos.	Se usan técnicas como la Regularización (L1/L2) para manejar muchas variables.
Validación	Pruebas de bondad de ajuste (Likelihood Ratio Test).	Validación Cruzada (Cross-Validation) y capacidad de generalización.

<https://towardsdatascience.com/logistic-regression-explained-a-visual-guide-with-code-examples-for-beginners-81baf5871505/>

Regresión logística apunte Universitat Oberta de Catalunya

https://cienciadedatos.net/documentos/27_regresion_logistica_simple_y_multiple

<https://cienciadedatos.net/documentos/py17-regresion-logistica-python>

<https://www.geeksforgeeks.org/machine-learning/understanding-logistic-regression/>

The Statquest illustrated guide to machine learning - Capítulo 6

Grokking Machine Learning - Capítulo 6

Regresión logística en Python