


Unidad 4

Fundamentos teóricos: hiperplano óptimo, vectores de soporte, margen duro y margen suave. Importancia del escalado de variables. Transformación a espacios de mayor dimensión y funciones kernel (lineal, polinomial, RBF). Selección de hiperparámetros y optimización. Aplicaciones espaciales.

Support vector machines


Support vector machines

Support vector machines es un algoritmo de aprendizaje supervisado cuyo objetivo fundamental es la clasificación y regresión. En la clasificación, SVM busca encontrar un hiperplano óptimo que separe las clases de datos en un espacio N-dimensional, donde N representa el número de características (features). Este hiperplano funciona como una frontera de decisión. En un espacio de dos dimensiones, este hiperplano es una línea recta.




Support vector machines


Para un conjunto de datos donde las clases son linealmente separables, puede existir un número infinito de hiperplanos que dividan correctamente los datos. La esencia de SVM radica en su criterio para seleccionar el “mejor” hiperplano. El algoritmo busca el único hiperplano que maximiza la distancia a los puntos de datos más cercanos de cada clase. Esta distancia total, desde el hiperplano hasta los puntos más cercanos de cada lado, se denomina margen.




Support vector machines



Classifier 1



Classifier 2




Classifier 3

La maximización del margen no es una simple preferencia geométrica; es un principio fundamental para mejorar la robustez y la capacidad de generalización del clasificador. Un margen más amplio implica una mayor “zona de seguridad” o “confianza” en la clasificación de nuevos puntos de datos que se encuentren cerca de la frontera de decisión. Un hiperplano que pasa muy cercano de los puntos de una clase es sensible a pequeñas variaciones o ruido en los datos de entrenamiento; un ligero cambio en estos puntos podría alterar la frontera de decisión.


Support vector machines

El hiperplano que maximiza el margen es único. La unicidad de esta solución no es casualidad, ya que la tarea de encontrar el hiperplano de margen máximo se plantea como un problema de optimización convexa. Un problema de convexo garantiza que cualquier mínimo local encontrado es también el mínimo global. Esta propiedad le confiere una ventaja a los SVM respecto a otros algoritmos, por ejemplo, las redes neuronales.



Support vector regression (SVR)



El marco conceptual de las SVM puede ser adaptado para resolver problemas de regresión, donde el objetivo es predecir un valor numérico en lugar de una etiqueta de clase. Esta variante se conoce como support vector regression. En vez de buscar un hiperplano que se ajuste a los datos de tal manera que la mayor cantidad posible de puntos de entrenamiento se encuentran en un “tubo” o margen de tolerancia. Este tubo está definido por el hiperplano central y dos planos paralelos a un plano de distancia de él.



*Truco del
kernel*



Casos no separables linealmente

Podemos separar mediante una línea




NO PODEMOS separar mediante una línea

Casos no separables linealmente




SOLUCIÓN: PROYECTAR A UN NUEVO ESPACIO DE OTRAS DIMENSIONES



Truco del kernel y datos linealmente no separables


Una gran cantidad de problemas del mundo real involucran datos que no pueden ser separados por una simple línea recta o hiperplano. En estos casos, las SVM lineales fallan y se requiere el truco del kernel.

El truco del kernel es una de las innovaciones más potentes y dota a las SVM de extraordinaria flexibilidad. La idea central es transformar los datos desde su espacio de características original a un espacio de mayor dimensionalidad donde se vuelven linealmente separables.




Truco del kernel

Esta transformación se realiza de manera implícita y eficiente. En lugar de calcular explícitamente las coordenadas de cada punto de datos en el nuevo espacio de alta dimensión, lo cual sería prohibitivamente costoso, una función kernel calcula directamente el producto escalar entre las imágenes de dos puntos en ese espacio de mayor dimensión.



X1



SVM kernel

The **linear kernel** does not transform the data at all. Therefore, it can be expressed simply as the dot product of the features:

$$K(\vec{x}_i, \vec{x}_j) = \vec{x}_i \cdot \vec{x}_j$$

The **polynomial kernel** of degree d adds a simple nonlinear transformation of the data:

$$K(\vec{x}_i, \vec{x}_j) = (\vec{x}_i \cdot \vec{x}_j + 1)^d$$

The **sigmoid kernel** results in an SVM model somewhat analogous to a neural network using a sigmoid activation function. The Greek letters kappa and delta are used as kernel parameters:

$$K(\vec{x}_i, \vec{x}_j) = \tanh(\kappa \vec{x}_i \cdot \vec{x}_j - \delta)$$

The **Gaussian RBF kernel** is similar to an RBF neural network. The RBF kernel performs well on many types of data and is thought to be a reasonable starting point for many learning tasks:


$$K(\vec{x}_i, \vec{x}_j) = e^{\frac{-||\vec{x}_i - \vec{x}_j||^2}{2\sigma^2}}$$

TABLE I. DIFFERENT KERNEL FUNCTIONS OF SVM


	Formula	Parameters	Merits
<i>Linear</i>	$K(x, x_i) = x \cdot x_i$	/	It is only used when the sample is separable in low dimensional space.
<i>Polynomial</i>	$K(x, x_i) = [\gamma * (x \cdot x_i) + coef]^d$	$\gamma, coef, d$	global kernels
<i>RBF</i>	$K(x, x_i) = \exp(-\gamma * \ x - x_i\ ^2)$	γ .	good local performance
<i>Sigmoid</i>	$K(x, x_i) = \tanh(\gamma(x \cdot x_i) + coef)$	$\gamma, coef$	needs to meet certain conditions

SVM y sus variantes


Podemos tener un límite de decisión lineal, cuadrático y polinómico.



Lineal




Cuadrático




Polinómico

SVM y sus variantes




SVM lineal




Puntos: Los datos rojos y azules están relativamente bien separados. Hay una línea recta clara que podría dividirlos.

Clasificación: El modelo Linear SVM ha encontrado una línea recta (el límite de decisión) que separa muy bien las dos clases. La región azul (clase azul) está en su mayoría a un lado, y la región roja (clase roja) al otro.



Puntos: Los datos rojos y azules están muy mezclados, superpuestos unos con otros. No hay una línea recta clara que pueda separarlos de manera efectiva.


Clasificación: El modelo Linear SVM intenta encontrar la mejor línea recta posible para dividir las clases, pero debido a la alta mezcla de los datos, la línea que encuentra solo logra dividir una pequeña parte. La región roja y la región azul se extienden sobre puntos de la clase opuesta.



Puntos: Similar a la primera situación, los datos rojos y azules están bien agrupados y tienen una clara separación, aunque el agrupamiento general puede tener una ligera inclinación.

Clasificación: El modelo Linear SVM ha encontrado un límite de decisión lineal (recto) que separa casi perfectamente las dos clases, demostrando que estos datos son casi linealmente separables.

SVM RBF



Puntos: Los datos rojos y azules están relativamente bien separados. Hay una línea recta clara que podría dividirlos.


Clasificación: El RBF SVM ha capturado perfectamente la **forma no lineal** de los datos. El límite de decisión (donde el color cambia de rojo a azul) es **curvo** y sigue la separación natural de las clases.

Puntos: Los datos rojos y azules están muy mezclados, superpuestos unos con otros. No hay una línea recta clara que pueda separarlos de manera efectiva.

Clasificación: El RBF SVM detecta esta estructura circular y crea un límite de decisión **redondo u ovalado** que encierra a la mayoría de los puntos azules, dejando la región roja en el exterior.


Puntos: Similar a la primera situación, los datos rojos y azules están bien agrupados y tienen una clara separación, aunque el agrupamiento general puede tener una ligera inclinación.

Clasificación: El modelo RBF SVM traza un límite de decisión **curvo y suave** que se ajusta a la forma en que los datos rojos y azules se separan.




Puntos: Los datos rojos y azules están relativamente bien separados. Hay una línea recta clara que podría dividirlos.

Clasificación: El modelo Poly SVM logra encontrar un límite de decisión **curvo** (polinomial) que se ajusta bien a la separación entre las clases. Las regiones roja y azul están bien definidas.



Puntos: Los datos rojos y azules están muy mezclados, superpuestos unos con otros. No hay una línea recta clara que pueda separarlos de manera efectiva.


Clasificación: El Poly SVM intenta trazar un límite de decisión curvo (posiblemente con múltiples inflexiones) para clasificar los puntos. Sin embargo, debido a la naturaleza aleatoria y mezclada de los datos, el límite de decisión es complejo, pero poco efectivo.



Puntos: Similar a la primera situación, los datos rojos y azules están bien agrupados y tienen una clara separación, aunque el agrupamiento general puede tener una ligera inclinación.

Clasificación: El Poly SVM traza un límite de decisión **curvo** que se desvía ligeramente de una línea recta para adaptarse mejor a la concentración de los puntos. Sin embargo, la separación no es tan limpia como en la Situación 1.

SVM Sigmoid



Puntos: Los datos rojos y azules están relativamente bien separados. Hay una línea recta clara que podría dividirlos.

Clasificación: El modelo Sigmoid SVM genera un límite de decisión con **varias curvas o "alas"** que intentan encerrar las regiones. Observa cómo el límite no es suave como el RBF, sino que tiene regiones más angulares o segmentadas. Logra separar una porción significativa de los datos, aunque con algunos errores.

Puntos: Los datos rojos y azules están muy mezclados, superpuestos unos con otros. No hay una línea recta clara que pueda separarlos de manera efectiva.

Clasificación: El Sigmoid SVM produce un **límite de decisión muy complejo y fragmentado**, con varias regiones pequeñas de color rojo y azul, lo que sugiere que el modelo está luchando por encontrar una generalización clara. El límite parece ser influenciado fuertemente por puntos individuales (vectores de soporte).

Puntos: Similar a la primera situación, los datos rojos y azules están bien agrupados y tienen una clara separación, aunque el agrupamiento general puede tener una ligera inclinación.

Clasificación: El Sigmoid SVM encuentra un límite de decisión **curvo y algo segmentado** que logra separar la mayoría de los puntos azules y rojos. El límite se ajusta para incluir la mayoría de los puntos en sus respectivas regiones.

El **RBF SVM** es ideal para datos que tienen **patrones circulares, espirales o cualquier otro patrón no lineal** y logra una precisión muy alta al encontrar **límites de decisión curvos** que se adaptan a la complejidad de la separación de las clases.


El Poly SVM es útil cuando la relación entre las clases se puede describir mediante una **curva suave o un límite de decisión de orden superior** (polinomial).

Precisión más variable: La precisión del Poly SVM a menudo depende fuertemente de la elección del **grado del polinomio**. Si el grado no es correcto, puede funcionar peor que el RBF SVM (que es más "flexible" para encontrar formas) o incluso peor que un Linear SVM (si los datos fueran casi lineales).


El Kernel Sigmoide es **menos utilizado** que el RBF o el Polinomial en la práctica de SVM, ya que a menudo puede producir resultados inconsistentes o límites de decisión extrañamente segmentados, como se ve en estas gráficas.

A veces, tiene un comportamiento similar a un **clasificador lineal** (si los parámetros del kernel son pequeños), y otras veces, produce un **límite de decisión muy local y segmentado** (como se ve en la Situación 2), lo que puede indicar que está ajustando demasiado el ruido en los datos.

Límites de decisión lineales vs no-lineales




SVM polynomial kernel / SVM radial kernel




A veces un mismo dataset puede separarse mediante dos kernel diferentes

FIGURE 9.9. Left: An SVM with a polynomial kernel of degree 3 is applied to the non-linear data from Figure 9.8, resulting in a far more appropriate decision rule. Right: An SVM with a radial kernel is applied. In this example, either kernel is capable of capturing the decision boundary.

SVM lineal vs SVM Gaussian RBF kernel



(a) linear classifier



(b) Gaussian-RBF kernel


Figure 8.9: For (a) a noisy data set that linear classifier appears to work quite well, (b) using the Gaussian-RBF kernel with the hard-margin SVM leads to overfitting.

A veces un mismo dataset puede separarse mediante dos kernel diferentes

Kernel Polinomial

Si quisiéramos separar estos puntos mediante SVM:


x_1	x_2	y
0.3	0.3	0
0.2	0.8	0
-0.6	0.4	0
0.6	-0.4	0
-0.4	-0.3	0
0	-0.8	0
-0.4	1.2	1
0.9	-0.7	1
-1.1	-0.8	1
0.7	0.9	1
-0.9	0.8	1
0.6	-1	1




Kernel Polinomial

Calculamos el cuadrado de cada variable y la sumamos.

x_1	x_2	$x_1^2 + x_2^2$	y
0.3	0.3	0.18	0
0.2	0.8	0.68	0
-0.6	0.4	0.52	0
0.6	-0.4	0.52	0
-0.4	-0.3	0.25	0
0	-0.8	0.64	0
-0.4	1.2	1.6	1
0.9	-0.7	1.3	1
-1.1	-0.8	1.85	1
0.7	0.9	1.3	1
-0.9	0.8	1.45	1
0.6	-1	1.36	1



Kernel Polynomial



La transformación que se usa aquí es elevar la "altura" de cada punto z según la suma de los cuadrados de sus coordenadas:

$$z = x_1^2 + x_2^2.$$

Los puntos que estaban cerca del origen (los **cuadrados anaranjados**) ahora tienen un valor z pequeño y están en la parte inferior del cono/paraboloide.

Los puntos que estaban lejos del origen (los **triángulos azules**) ahora tienen un valor z grande y están en la parte superior.

A partir de kernels no lineales en SVM empezamos a tener modelos que tienen límites de decisión no lineales

Función de pérdida (loss function)

A diferencia de otros modelos que buscan minimizar el error cuadrático o la entropía cruzada, SVM busca maximizar el "margen" entre las clases.

1. La Función Hinge Loss

La pérdida para una sola observación se define matemáticamente como:

$$L(y, f(x)) = \max(0, 1 - y \cdot f(x))$$

Donde:

- y es la etiqueta real (+1 o -1).
- $f(x)$ es el valor predicho por el modelo (la distancia al hiperplano).

¿Cómo funciona la lógica?

- Si el punto está bien clasificado y fuera del margen ($y \cdot f(x) \geq 1$), la pérdida es 0.
- Si el punto está dentro del margen o mal clasificado, la pérdida aumenta linealmente según la distancia al "lado correcto" del margen.

Hiperparámetros y tuning

Parámetros son variables que definen el modelo entrenado mediante aprendizaje. Los parámetros son directamente modificados por el algoritmo de aprendizaje basado en los datos de entrenamiento. Ej, la pendiente y la ordenada de una recta en regresión lineal simple.

Hiperparámetros son variables internas de un algoritmo de ML que influyen la performance del modelo. No pueden ser aprendidos mediante el algoritmo de ML, ya que son definidos por el usuario, aunque lo más común es realizar una búsqueda de hiperparámetros (en grilla o de manera aleatoria son las formas de búsqueda más comunes). Ej: profundidad de un árbol en árboles de decisión, el K óptimo en KNN.

En SVM vamos a tener hiperparámetros para optimizar

El margen blando (soft margin)

Para manejar datos que no son linealmente separables, se introduce el concepto de margen blando (soft margin). Este enfoque es más flexible, ya que permite que algunas muestras de datos violen el margen, es decir, que se encuentren dentro de él o incluso en el lado incorrecto del hiperplano. La idea es permitir una pequeña cantidad de errores de clasificación a cambio de encontrar una frontera de decisión que tenga un margen más amplio y, por lo tanto, manejar una mejor capacidad de generalización.

La implementación matemática del margen blando se logra mediante la introducción de variables de holgura (slack variables), denotadas por epsilon $\xi \geq 0$ para cada punto de datos x_i . Estas variables miden el grado en que un punto viola la restricción de margen.


El margen blando (soft margin)

Si $\xi = 0$, el punto está correctamente clasificado y fuera del margen. Si $0 < \xi < 1$, el punto está dentro del margen pero aún en el lado correcto del hiperplano. Si $\xi > 1$, el punto está mal clasificado.

La restricción se relaja a:

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 - \xi_i$$

Para controlar el número y la magnitud de estas violaciones se introduce el hiperparámetro C .



$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i$$

El margen blando (soft margin)





Soft-margin

Hard-margin

small C

medium C

large C



$$\min_{\omega, b, \zeta} \frac{1}{2} w^T w + C \sum_{i=1}^n \zeta_i$$

- **Lineal: Parámetro C**

where ζ_i denotes the distance to the correct margin with $\zeta_i \geq 0$, $i = 1, \dots, n$

where C denotes a regularization parameter

where $w^T w = \|w\|^2$ denotes the normal vector

where $\phi(x_i)$ denotes the transformed input space vector

where b denotes a bias parameter

where y_i denotes the i -th target value

El **parámetro C** es un hiperparámetro de regularización en el modelo SVM. Controla el equilibrio entre maximizar el margen entre las clases y minimizar el error de clasificación.

- **Valores altos de C:** El modelo penaliza más los errores de clasificación, tratando de clasificar correctamente todos los puntos de entrenamiento, lo cual puede llevar a un margen más pequeño y riesgo de sobreajuste (overfitting).
- **Valores bajos de C:** El modelo permitirá algunos errores de clasificación a favor de un margen más amplio entre las clases, promoviendo un modelo más generalizado.

Este parámetro es útil en problemas donde es importante evitar el sobreajuste.

- **RBF Kernel: C y gamma.**


$$k(\mathbf{x}, \mathbf{y}) = e^{-\gamma \|\mathbf{x} - \mathbf{y}\|^2}, \gamma > 0$$

Cuando se usa el **kernel RBF (Radial Basis Function)** en un SVM, se introduce el parámetro **gamma**, que define cómo afecta la influencia de un punto de entrenamiento en la clasificación.

- **Valores altos de γ (gamma):** Cada punto de entrenamiento tiene una influencia muy cercana, lo que permite que el modelo se ajuste a detalles específicos de los datos, aumentando el riesgo de sobreajuste.
- **Valores bajos de γ (gamma):** Los puntos de entrenamiento tienen una influencia más amplia, lo que ayuda a capturar tendencias generales en los datos, promoviendo un modelo más generalizado y evitando el sobreajuste.

Valores de γ

The parameter γ controls the width of the Gaussian kernel. Different choices for the width γ correspond to different geometries in the infinite-dimensional $\mathcal{Z}$ space, much like how different choices for (γ, ζ) in the polynomial kernel correspond to different geometries in the polynomial $\mathcal{Z}$ space. The following figures show the classification results of three Gaussian-RBF kernels only differing in their choice of γ .




Al aumentar
gamma
aumenta el
overfitting

Hiperparámetros y Overfitting

aumenta gamma

Mantengo constante C
a lo largo de la fila

Aumenta C



Hiperparámetros y Overfitting


Aumenta overfitting

aumenta gamma

Mantengo constante C a lo largo de la fila

Aumenta C

Aumenta overfitting




Hiperparámetros y Overfitting


aumenta gamma



C = 0.1000 gamma = 0.01




C = 0.1000 gamma = 0.10



C = 0.1000 gamma = 1.00



C = 0.1000 gamma = 5.01



C =



01



C = 10



5.01



VAMOS A PREFERIR
VALORES:

- BAJOS DE C
- BAJOS DE GAMMA

Mantengo
constante C
a lo largo de la
fila

Aumenta
C





SIEMPRE DEBEMOS EVITAR OVERFITTING

- Modelos más simples
- Evaluación mediante validación cruzada
- Regularización
- Obtener más datos
- Ensemble learning

SVM Demo

<https://jgreitemann.github.io/svm-demo>



Ventajas y Desventajas de SVM

Strengths	Weaknesses
• Can be used for classification or numeric prediction problems • Not overly influenced by noisy data and not very prone to overfitting • May be easier to use than neural networks, particularly due to the existence of several well-supported SVM algorithms • Gained popularity due to their high accuracy and high-profile wins in data mining competitions	• Finding the best model requires the testing of various combinations of kernels and model parameters • Can be slow to train, particularly if the input dataset has a large number of features or examples • Results in a complex black-box model that is difficult, if not impossible, to interpret

Ventajas y Desventajas de SVM

Ventajas:

- Eficaz en espacios de altas dimensiones.
- Todavía efectivo en casos donde el número de dimensiones es mayor que el número de muestras.
- Versatilidad en cuanto a los kernels que se pueden emplear.

Desventajas:

- Si el número de muestras $<$ número de dimensiones, es esencial evitar el overfitting mediante regularización y un kernel apropiado.
- SVMs no proveen probabilidades a diferencia de la regresión logística.

Fuente: <https://scikit-learn.org/stable/modules/svm.html>

Recordar

Regresión
lineal

Regresión

Regresión
logística

Clasificación

SVM

Regresión y
clasificación


Importante recordar que con SVM podemos hacer clasificaciones y regresiones.

Para profundizar SVM



Learning from data

Lecture 14: <https://l1nq.com/jelq55m>




Chapter 8

Support Vector Machines

Linear models are powerful. The nonlinear transform and the neural network (a cascade of linear models) are tools that increase their expressive power. Increasing the expressive power has a price: overfitting and computation time. Can we get the expressive power without paying the price? The answer is yes. Our new model, the Support Vector Machine (SVM), uses a 'safety cushion' when separating the data. As a result, SVM is more robust to noise; this helps combat overfitting. In addition, SVM can work seamlessly with a new powerful tool called the *kernel*: a computationally efficient way to use high (even infinite!) dimensional nonlinear transforms. When we combine the safety cushion of SVM with the 'kernel trick', the result is an efficient powerful nonlinear model with automatic regularization. The SVM model is popular because it performs well in practice and is easy to use. This chapter presents the mathematics and algorithms that make SVM work.

8.1 The Optimal Hyperplane

Let us revisit the perceptron model from Chapter 1. The illustrations below on a toy data set should help jog your memory. In 2 dimensions, a perceptron attempts to separate the data with a line, which is possible in this example.




Búsqueda de hiperparámetros


Búsqueda de hiperparámetros

Cuando hacemos tuning de hiperparámetros lo que hacemos es encontrar valores óptimos de los hiperparámetros. Esa búsqueda puede hacerse en grilla (grid search), aleatoria (random search), en forma bayesiana (bayesian optimization).


Grid Search



Random Search




Bayesian Optimization



Búsqueda de hiperparámetros


También podemos hacer tuning de hiperparámetros con hyperband, algoritmos genéticos.



- El **Grid Search** es la estrategia más simple y exhaustiva. Consiste en definir un conjunto finito de valores discretos para cada hiperparámetro. El algoritmo prueba **cada combinación posible** de estos valores.
- El **Random Search** aborda la limitación de la Búsqueda en Cuadrícula. En lugar de probar todas las combinaciones, define un **rango de valores** (continuos o discretos) para cada hiperparámetro y luego selecciona combinaciones de forma **aleatoria** dentro de esos rangos para un número fijo de iteraciones.
- La **Optimización Bayesiana** es la estrategia más sofisticada. Se trata de un método **secuencial** que utiliza los resultados de las evaluaciones anteriores para guiar de manera inteligente la búsqueda de la siguiente combinación de hiperparámetros. Utiliza un modelo probabilístico (generalmente un Proceso Gaussiano) para predecir qué regiones del espacio de búsqueda tienen más probabilidades de contener el óptimo.

- **Hyperband:** Es una estrategia basada en el **detenimiento temprano (early stopping)** que optimiza el uso de recursos. En lugar de entrenar cada configuración hasta el final, Hyperband lanza muchas combinaciones con muy pocos recursos (pocos datos o épocas), descarta rápidamente las que rinden mal y concentra todo el presupuesto de cómputo solo en las "promesas" que pasan a las siguientes rondas. Es como un torneo de eliminación directa donde solo los mejores modelos llegan a la final (<https://jmlr.org/papers/v18/16-558.html>).
- **Algoritmos genéticos:** Es una estrategia inspirada en la **evolución biológica** que busca la combinación óptima mediante ciclos de selección y reproducción. Comienza con una población aleatoria de configuraciones ("individuos"); las mejores sobreviven y se combinan entre sí (cruce), aplicando pequeñas variaciones aleatorias (mutaciones) para generar una nueva generación. Este proceso se repite hasta que la población converge hacia los hiperparámetros que maximizan la precisión del modelo.

Flujo de trabajo



Tuning de hiperparámetros

Encontrar los valores de los hiperparámetros de un algoritmo de aprendizaje que producen el mejor modelo.

Aplicaciones Espaciales

Sub-spatial prediction of votes integrating socioeconomic, educational, and age strata with machine learning and topological data analysis






Fig. 8 ROC curve for the SVC cor+seg model



(a) Box plot of the best classification models labeled **C** and machine learning methods. Here the numbers are as follows: SVC **C** TDA: 1, RF **C** TDA : 2, NN **C** TDA : 3, SVC **C** cor+seg: 4, RF **C** cor+seg: 5, and NN **C** cor+seg: 6



Aplicación SVM

OPEN An integrated approach of support vector machine (SVM) and weight of evidence (WOE) techniques to map groundwater potential and assess water quality





Figure 7. Groundwater potential map produced through a) WOE method, b) SVM model.

- Introduction to statistical learning
- Elements of statistical learning
- Brett Lantz. Machine learning with R
- Learning from data
- Grokking Machine Learning
- Python scikit learn documentation
(<https://scikit-learn.org/stable/modules/svm.html>)
- Starmer, J. *The StatQuest Illustrated Guide to Machine Learning* (2021).
- <https://pub.towardsai.net/decoding-linear-soft-svm-for-classification-over-linear-hard-svm-f84cbc111913>
- <https://medium.com/@jangdaehan1/harnessing-support-vector-machines-for-geo-spatial-data-analysis-a-comprehensive-exploration-c06713ad8e70>
- <https://www.nb-data.com/p/6-common-hyperparameter-optimization>

SVM Demo

<https://jgreitemann.github.io/svm-demo>

Práctica de SVM en Python