

Unidad 5

Random Forest. Modelos de ensemble y bias-variance trade-off. Tipos de ensemble. Bias y varianza en bagging, boosting, stacking. Concepto de bagging. Bagging para regresión y clasificación. Algoritmo de Bagging. Random Forests, concepto. Diferencia con árboles de decisión y bagging. Algoritmo de Random Forests. Hiperparámetros para tuning de random forests. ExtraTrees, concepto. Diferencia con random forests y bagging. Aplicaciones espaciales.

Ensembles

En el aprendizaje automático el objetivo fundamental es aprender una función de mapeo que pueda generalizar de manera efectiva para predecir los resultados de datos nuevos y no vistos. El desarrollo de cualquier modelo predictivo se enfrenta a un desafío inherente conocido como trade-off entre sesgo y varianza.


Sesgo (bias): se refiere al error introductorio por aproximar un problema del mundo real, que puede ser muy complejo, mediante un modelo demasiado simple. Un modelo con alto sesgo hace suposiciones erróneas sobre los datos, lo que le impide capturar las relaciones subyacentes y conduce a un rendimiento deficiente tanto en training como en testing, llevando a underfitting.

Variancia (variance): mide la sensibilidad del modelo a pequeñas fluctuaciones en el conjunto de datos de entrenamiento. Un modelo con alta varianza presta atención a los datos de entrenamiento, llegando a modelar el ruido aleatorio presente en ellos. Esto lleva a buenos valores training y bajos valores en testing, llevando a overfitting.

Los modelos de ensemble surgen como una solución poderosa y elegante al dilema sesgo-varianza. En lugar de depender de un único modelo, estos métodos combinan las predicciones de múltiples modelos base, a menudo, llamados weak learners (aprendices débiles), para construir un modelo final más robusto, estable y preciso.

Este modelo se fundamenta en la reducción del error. Si se promedian las predicciones de un conjunto de estimadores independientes e idénticamente distribuidos, la varianza de la media es significativamente menor que la varianza de un único estimador.

Modelos de ensemble




Varios aprendices débiles se combinan para formar un aprendiz más robusto.

Figure 12.1 Ensemble methods consist of joining several weak learners to build a strong learner.

- Métodos Paralelos (Bagging): entrenan a los modelos base de forma independiente y simultánea, cada uno sobre un conjunto diferente de los datos. Su objetivo principal es reducir la varianza del modelo final.
- Métodos secuenciales (Boosting): entrenan modelos de manera secuencial. Cada nuevo modelo se enfoca en corregir los errores cometidos por los modelos anteriores, buscando principalmente reducir el sesgo.
- Apilamiento (stacking): combina las predicciones de varios modelos de base heterogéneos mediante el entrenamiento de un “meta-modelo” que aprende a ponderar óptimamente cada predicción.

Modelos de ensemble

Bagging (Bootstrap Aggregation)




Process Aggregate multiple models trained on different subsets bootstrap data.

Predictions Averaging (regression) or Voting (classification).

Example Random Forest, Bagged Decision Trees.

Boosting




Builds models sequentially and perform error correction based on previous model.

Weighted sum of predictions based on every model.

AdaBoost, Gradient Boosting Machines (GBM), XGBoost.

Stacking



Combines predictions of multiple models using a meta model.

Meta model give final prediction based on the multiple models prediction

Logistic Regression on top of multiple classifiers

Bias y varianza en bagging / boosting

En bagging, se emplean modelos con muy poco bias pero mucha varianza, agregándolos se consigue reducir la varianza sin apenas aumentar el bias.


En boosting, se emplean modelos con muy poca varianza pero mucho bias, ajustando secuencialmente los modelos se reduce el bias. Por lo tanto, cada una de las estrategias reduce una parte del error total.

En stacking, disminuimos el error total, combinando modelos que son heterogéneos y complementarios.


Bagging

- **Bootstrap (Muestreo con Reemplazo):** Se crean **múltiples subconjuntos de datos** (muestras *bootstrapped*) tomando muestras aleatorias del conjunto de entrenamiento **con reemplazo**. Esto significa que un mismo dato puede aparecer en varios subconjuntos.
- **Entrenamiento de Modelos Base:** Se entrena un **modelo base** (a menudo un árbol de decisión, aunque puede ser cualquier algoritmo) de forma **independiente** en cada uno de los subconjuntos de datos creados en el paso anterior.
- **Agregación (Aggregation):** Para obtener la predicción final, se **combinan** las predicciones de todos los modelos individuales:
 - Para **clasificación**, se utiliza la **votación por mayoría** (el resultado más frecuente).
 - Para **regresión**, se calcula el **promedio** de las predicciones.

Bagging



Bagging



Bagging vs árboles de decisión




Figure 7-5. A single Decision Tree versus a bagging ensemble of 500 trees

El bootstrapping o bagging introduce mayor diversidad en los subsets de datos en los que cada predictor es entrenado, lo que trae como consecuencia que el bias sea más alto que si no se hiciese bagging. Esto significa que el predictor termina siendo menos correlacionado, entonces la varianza del ensemble se reduce. En general, el bagging resulta en mejores modelos, lo que explica porque se lo prefiere a árboles de decisión.

Bagging






Figure 2.5 Bootstrap sampling leads to different base estimators overfitting differently, while model aggregation averages out individual mistakes and produces smoother decision boundaries.

Bagging para clasificación







Muestras a
clasificar






Bootstrap resampling








Bagging para clasificación



Base learners
(aprendices
base)





Bagging para clasificación




Majority vote
(voto por
mayoría)

$$\text{VOTE} (\text{orange square} , \text{blue circle} , \text{blue circle}) = \text{blue circle}$$

Bagging para regresión



Promediamos



```
1 for  $i = 1$  to  $m$  do  
2   |   Generate a bootstrap sample of the original data  
3   |   Train an unpruned tree model on this sample  
4 end
```

Algorithm 8.1: Bagging

Random Forests

La innovación fundamental de random forests sobre el bagging es la introducción de una segunda capa de aleatoriedad: la selección aleatorias de features o características (feature bagging o método del subespacio aleatorio).


El mecanismo es el siguiente: en cada nodo del árbol, antes de buscar la mejor división, el algoritmo selecciona un subconjunto aleatorio de m características del total de p características disponibles ($m < p$).

Si $m = p$, bagging y random forests son iguales

- Para clasificación, $m = \sqrt{p}$
- Para regresión, $m = p/3$

Si los predictores están muy correlacionados, un valor bajo de m , consiguen mejores resultados.

Standard decision tree: all features are available from which to select the best split.



Random decision tree: only some randomly selected subsets of features are available from which to select the best split.




Figure 2.7 Random forests use a modified tree learning algorithm, where a random feature subset is first chosen before the best splitting criterion for each decision node is identified. The unshaded columns represent features that have been left out; the lightly shaded columns represent available features from which the best feature is chosen, shown in the darkly shaded columns.

El propósito de esta técnica es descorrelacionar los árboles del bosque. Si no se aplica esta restricción, y existiera una feature muy predictiva en el conjunto de datos, la mayoría de los árboles tenderían a seleccionarla en sus primeras divisiones. Esto haría que las estructuras de los árboles fueran muy similares entre sí (altamente correlacionados), lo que limitaría drásticamente el beneficio de la reducción de varianza obtenido al promediarlos. Al forzar a cada división a considerar sólo un subconjunto aleatorio de predictores, se asegura que diferentes árboles exploren la importancia de diferentes features, generando un ensamble mucho más diverso. Esta doble aleatoriedad (en filas y columnas) es sinérgica: la selección de características potencia la efectividad del bagging.

Bagged Trees:

- Supongamos que tenemos un conjunto de datos con un predictor (o característica) muy fuerte, junto con otros predictivos que son menos influyentes.
- Cuando creamos varios árboles en un conjunto de **bagged trees** (o árboles con bootstrap), cada árbol tiende a seleccionar ese predictor fuerte para dividir los datos, ya que todos los árboles pueden acceder a todas las variables predictoras.
- Esto hace que todos los árboles se vean bastante similares y que sus predicciones estén **altamente correlacionadas**. Es decir, la predicción final que resulta del promedio de todos estos árboles será similar a la de un único árbol.
- Este alto grado de correlación es un problema, ya que si todos los árboles predicen de manera similar, promediarlos no ayuda a reducir la varianza tanto como se espera en técnicas de ensamble.


Random Forest:

- Para superar este problema, **Random Forest** impone una restricción: en cada división del árbol, sólo puede considerarse un subconjunto aleatorio de los predictores en lugar de todos.
- Así, es menos probable que el predictor fuerte esté siempre presente en cada división, lo cual fuerza a los árboles a explorar otros predictores.
- Este proceso se conoce como **descorrelación de los árboles**. Los árboles en un modelo de Random Forest tendrán predicciones menos correlacionadas entre sí.
- Debido a que sus predicciones son menos similares, el promedio de las predicciones de los árboles reduce la varianza de manera más efectiva, haciendo el modelo final más robusto y confiable.
- La principal diferencia entre **bagged trees y random forest** es precisamente este paso adicional en Random Forest, donde se selecciona un subconjunto de predictores en cada división para reducir la correlación entre los árboles.


Bagging es una estrategia general para cualquier modelo.

En Random Forest, en particular, aparte de bagging, hago un sampling de variables, que me permite reducir la varianza y obtener mejores predicciones.

Esquema de Random Forest



Cómo funciona el majority vote en RF



Tally: Six 1s and Three 0s

Prediction: 1

Random Forests




Figure 2.8 Random forest (top left) compared to individual base learners (randomized decision trees). Much like bagging, the random forest ensemble also produces a smooth and stable decision boundary. Also observe the effect of randomization on the individual trees, which are far spikier than regular decision trees.

Voto mayoritario

● ● ● ● ● ● ● ● ● ● Unanimity

● ● ● ● ● ● ▲ ▲ ▲ ▲ Majority

● ● ● ● ▲ ▲ ▲ □ □ □ Plurality

El **voto mayoritario (majority vote)** es el mecanismo fundamental que utilizan los Random Forests (y otros algoritmos de ensamblaje) para combinar las predicciones de sus múltiples modelos individuales y tomar una decisión final conjunta.

Selección por mayoría: El sistema recopila las predicciones de todos los árboles y **selecciona la etiqueta de clase que haya sido predicha por la mayoría de ellos**. En términos estadísticos, la predicción final del ensamblaje es la **moda** (el resultado más frecuente) de todas las predicciones individuales .

¿Por qué funciona? Al combinar las opiniones mediante el voto mayoritario, los errores cometidos por árboles individuales se "suavizan" o cancelan entre sí, lo que da como resultado una predicción final mucho más robusta y precisa que la que podría ofrecer un solo árbol.

Random Forests vs Árboles de Decisión

- Train: 90%
- Test: 10%

TABLE 2
Test set misclassification error (%)

Data set	Forest	Single tree
Breast cancer	2.9	5.9
Ionosphere	5.5	11.2
Diabetes	24.2	25.3
Glass	22.0	30.4
Soybean	5.7	8.6
Letters	3.4	12.4
Satellite	8.6	14.8
Shuttle $\times 10^3$	7.0	62.0
DNA	3.9	6.2
Digit	6.2	17.1

Fuente: Leo Breiman. *Statistical Modeling: The two cultures*

Random Forests es un algoritmo sencillo, fácil de implementar, fácil de usar y requiere tuning de pocos hiperparámetros.

A diferencia de árboles de decisión, puede ser menos interpretable.


```
1 Select the number of models to build,  $m$ 
2 for  $i = 1$  to  $m$  do
3   Generate a bootstrap sample of the original data
4   Train a tree model on this sample
5   for each split do
6     Randomly select  $k$  ( $< P$ ) of the original predictors
7     Select the best predictor among the  $k$  predictors and
       partition the data
8   end
9   Use typical tree model stopping criteria to determine when a
     tree is complete (but do not prune)
10 end
```

Algorithm 8.2: Basic Random Forests

- Documentación de random forest classifier:

<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>

- Documentación de random forest regressor:

<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>



Hiperparámetros en random forests

- Hiperparámetros estructurales (del bosque)
- Hiperparámetros de control en los árboles (poda y complejidad)
- Otros hiperparámetros de utilidad

Diferencias de criterio

Hiperparámetro	RandomForestClassifier	RandomForestRegressor
criterion	"gini", "entropy", "log_loss"	"squared_error", "absolute_error", "friedman_mse", "poisson"
Uso principal	Mide la impureza de las clases.	Mide el error de predicción numérica.

1. Hiperparámetros Estructurales (Del Bosque)

Estos controlan la composición general de tu modelo:

- **n_estimators**: El número de árboles en el bosque. Más árboles suelen dar mejor rendimiento pero aumentan el tiempo de cómputo. (Por defecto: **100**).
- **bootstrap**: Indica si se utilizan muestras de *bootstrap* (muestreo con reemplazo) para construir los árboles. Si es **False**, se usa todo el dataset para cada árbol. (Por defecto: **True**).
- **oob_score**: Si es **True**, usa muestras "out-of-bag" para estimar la precisión de generalización. Solo funciona si **bootstrap=True**.
- **n_jobs**: El número de hilos de CPU que quieres usar en paralelo. **-1** significa usar todos los procesadores disponibles.

2. Hiperparámetros de Control de los Árboles (Poda y Complejidad)

Aquí es donde evitas el **overfitting** (sobreajuste):

- **max_depth**: La profundidad máxima de cada árbol. Si es **None**, los árboles crecen hasta que las hojas sean puras. Limitarlo es clave para modelos más simples.
- **min_samples_split**: El número mínimo de muestras requeridas para dividir un nodo interno. Puede ser un número entero o una fracción.
- **min_samples_leaf**: El número mínimo de muestras que debe tener una hoja (nodo terminal). Ayuda mucho a suavizar el modelo.
- **max_features**: El número de características a considerar al buscar el mejor corte. Puede ser "sqrt", "log2", un número fijo o un porcentaje. **Es fundamental para la diversidad del bosque.**

3. Otros Hiperparámetros de Utilidad

- **random_state**: Controla la aleatoriedad. Úsalo si quieres que tus resultados sean replicables (siempre obtendrás el mismo modelo con el mismo número).
- **class_weight** (Solo en Classifier): Muy útil si tienes clases desbalanceadas (ej: más ceros que unos). Puedes ponerlo en "balanced".
- **max_samples**: Si **bootstrap=True**, define cuántas muestras extraer de X para entrenar cada árbol base.

Ventajas y desventajas de Random Forests

The following table summarizes the strengths and weaknesses of random forest models:

Strengths	Weaknesses
• An all-purpose model that performs well on most problems, including both classification and numeric prediction • Can handle noisy or missing data as well as categorical or continuous features • Selects only the most important features • Can be used on data with an extremely large number of features or examples	• Unlike a decision tree, the model is not easily interpretable • May struggle with categorical features with very large numbers of levels • Cannot be extensively tuned if greater performance is desired

Extra Trees

Extra Trees: extremely randomized trees.

Cuando crece un árbol con Random Forest, en cada nodo sólo una parte aleatoria de los features es considerada para el split. Es posible hacer que los árboles aún sean más aleatorios usando umbrales aleatorios para cada feature (variable) en vez de buscar los mejores posibles umbrales (como en árboles de decisión).

Un árbol de árboles tan aleatorios, simplemente se los llama Extremely Randomized Trees o ExtraTrees. De vuelta esto intercambia más bias por menos varianza. Esto que hace que los ExtraTrees sean más rápidos de entrenar que los Random Forests ya que encontrar el mejor umbral posible para cada feature a cada nodo es la tarea más cara computacionalmente.

Uso completo del conjunto de datos: A diferencia de Random Forest, cada árbol utiliza el conjunto de datos de entrenamiento completo en lugar de una muestra de arranque.

Selección aleatoria de características: Al realizar una división, cada árbol solo considera un subconjunto aleatorio de características (normalmente la raíz cuadrada de las características totales), similar a Random Forest.

Selección dividida aleatoria: La diferencia clave está en dividir — en lugar de buscar el umbral óptimo, Extra Trees genera aleatoriamente varios puntos de división para cada característica y elige el mejor entre estas divisiones aleatorias. Esto lo hace mucho más rápido que Random Forest.

Árboles en crecimiento: Cada árbol crece utilizando estas divisiones extremadamente aleatorias hasta que alcanza un punto de parada (como grupos puros o tamaño mínimo de muestra).

Predicción final: Todos los árboles votan juntos para la predicción final. Para la clasificación, tome el voto mayoritario de las predicciones de clase; para la regresión, promedie los valores predichos de todos los árboles.

Bagged Trees

- Mejores árboles
- Árboles más similares


Random Forest

- Árboles más débiles
- Árboles menos similares

Extra Trees

- Árboles aún más débiles
- Árboles aún menos similares



Extra Trees vs Random Forest





Algoritmo	Fuente de aleatoriedad
Bagging	Bootstrap: muestreo con reemplazo + todas las variables (columnas)
Random Forests	Bootstrap + sampling de variables (splits óptimos)
Extra Trees	Sampling de variables + splits no óptimos. No realiza bootstrapping.

Aplicaciones Espaciales

Selection and prediction of metro station sites based on spatial data and random forests: a study of Langzhou, China




Improving land cover classification in an urbanized coastal area by random forests: The role of variable selection



<https://www.sciencedirect.com/science/article/abs/pii/S0034425720304788>

Fig. 2. The work procedural route used to identify the optimal random forest model for land cover classification.



Geographically weighted random forests for macro-level frequency prediction






Fig. 1. Local road network of London.



(a)



(b)

Fig. 2. Distribution of population density of examples.

Recordar

Regresión lineal

Regresión

Regresión logística

Clasificación

SVM

Árboles de decisión

Random Forests

Regresión y clasificación

Con random forest podemos hacer regresiones y clasificaciones, al igual que con SVM y decision trees.

- Introduction to statistical learning. Capítulo 8
- The elements of statistical learning. Capítulo 15
- Grokking Machine Learning. Capítulo 12.
- Ensembles for Machine Learning. Capítulo 1 y 2.
- Applied Predictive Modeling. Capítulo 8
- Extra Trees. Explicación visual
<https://medium.com/@samybaladram/extra-trees-explained-a-visual-guide-with-code-examples-4c2967cedc75>
- <https://www.youtube.com/watch?v=clbj0WuK41w>
- Clase ensembles Sebastian Raschka
(https://sebastianraschka.com/pdf/lecture-notes/stat451fs20/07-ensembles_slides.pdf)