

Unidad 6

Aprendizaje no supervisado, definición, tipos, desafíos. Concepto de distancia. Clustering Espacial I: K-Means y Detección de Patrones. Teoría: Algoritmo K-Means, elección de K. Pasos, ventajas y desventajas. Clustering jerárquico: algoritmos aglomerativos y divisivos. Distintos tipos de linkage. Ventajas y desventajas. Algoritmo. *Clustering Espacial II: DBSCAN y Patrones Irregulares*. Teoría: Density-Based Spatial Clustering, detección de outliers.

Aprendizaje no supervisado

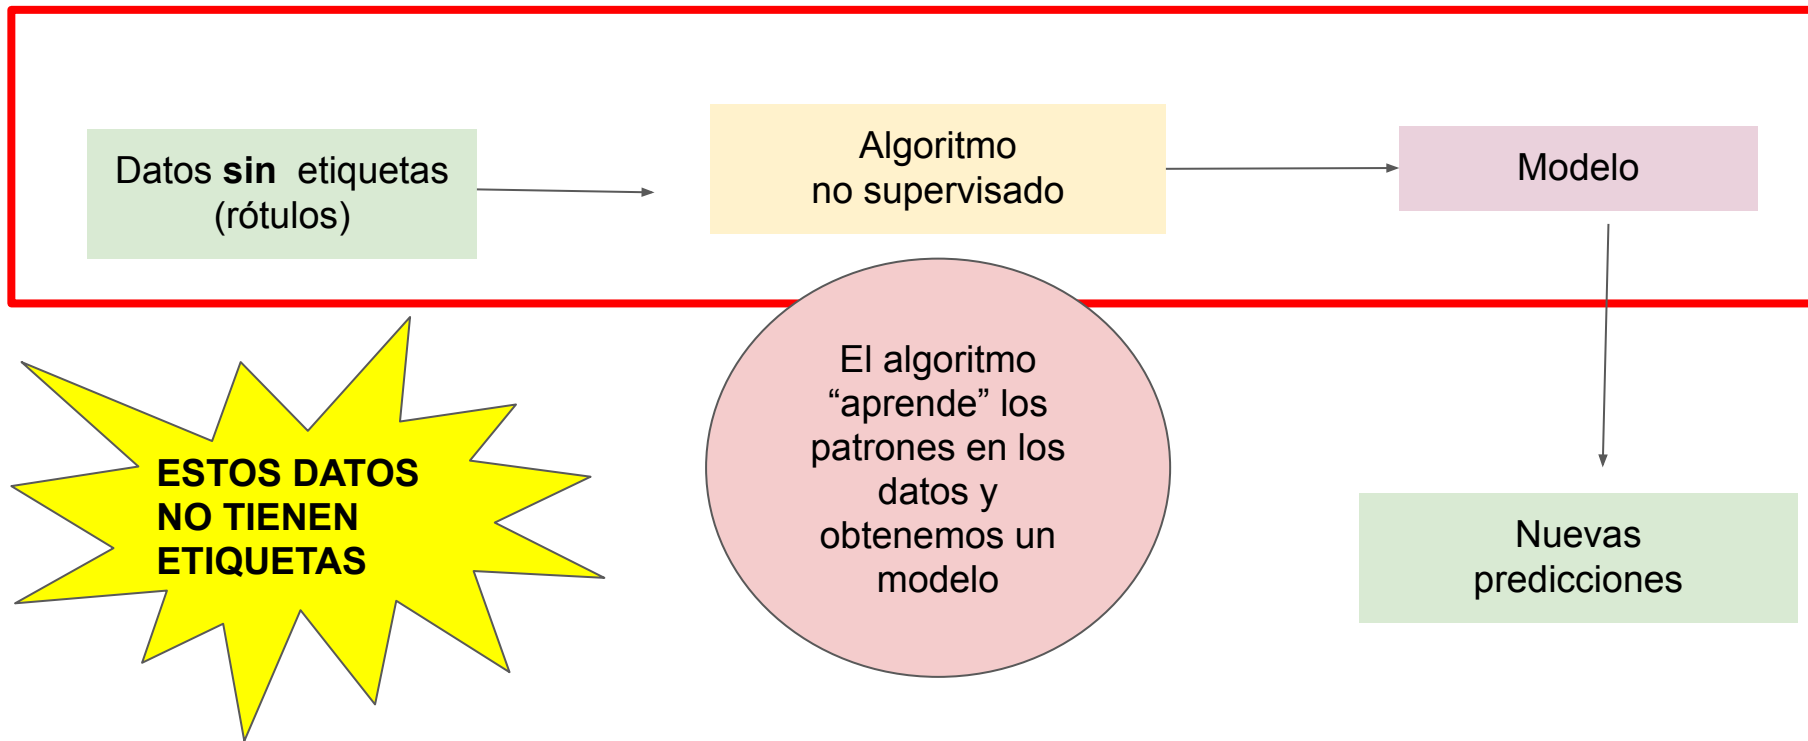
Aprendizaje No Supervisado (definición matemática)

- Tenemos un set de features (variables, columnas) $X_1, X_2, \dots, X_p$ medidas en n observaciones. Al no tener la variable Y , no nos interesa la predicción.
- Sin embargo, nos interesa descubrir cosas interesantes sobre / estudiar las variables $X_1, X_2, \dots, X_p$.
- ¿Existe alguna forma informativa de visualizar las variables?
- ¿Podemos descubrir agrupaciones entre las variables o entre las muestras (filas)?

Aprendizaje no supervisado

RECORDEMOS

Entrenamiento del modelo



Aprendizaje no supervisado

RECORDEMOS

Datos **sin** etiquetas
(rótulos)

**Algoritmo
no supervisado**


Modelo

Nuevos datos

Nuevas
predicciones

**ESTOS DATOS
NO TIENEN
ETIQUETAS**

Este modelo obtenido lo
utilizamos para
encontrar relaciones
ocultas entre datos



Tipos de aprendizaje no supervisado

Algoritmos
de clustering

Dividir / “Particionar” los datos en grupos distintos de ítems (filas) similares.

Reducción de
dimensiones
(*transformaciones
no supervisadas*)

Algoritmos que crean nuevas representaciones de los datos las cuales pueden ser más fáciles para otros humanos o algoritmos de ML para entender a comparación de la representación original de los datos.

Desafíos del aprendizaje no supervisado

- Ausencia de labels, rótulos o etiquetas hace que nos resulte complicado evaluar un modelo de aprendizaje no supervisado.
- Como consecuencia, este tipo de algoritmos se utilizan con **fines exploratorios de los datos**, para poder entenderlos mejor.
- También este tipo de algoritmos se utilizan como parte del **pre-procesamiento de datos**. Ejemplo: embeddings, PCA (proyectar mis datos a otras dimensiones).

Distancia y Clustering

Se da, en general, el *nombre de distancia o disimilaridad entre dos individuos i y j a una medida, indicada por $d(i,j)$, que mide el grado de semejanza, o a mejor decir de desemejanza, entre ambos objetos o individuos, en relación a un cierto número de características cuantitativa y / o cualitativas.*

El valor de $d(i,j)$ es siempre un valor no negativo, y cuanto mayor sea este valor mayor será la diferencia entre los individuos i y j .

Toda distancia debe verificar, al menos, las siguientes propiedades:

$$(1) \quad d(i,j) > 0 \text{ (no negatividad)}$$










$$(2) \quad d(i,i) = 0$$

$$(3) \quad d(i,j) = d(j,i) \text{ (simetría)}$$

Diremos que una distancia es euclídea cuando puede encontrarse un espacio vectorial de dimensión igual o inferior a la dimensión del espacio de variables en el que podamos representar a los individuos por puntos cuya distancia euclídea ordinaria coincida con la distancia utilizada.


Distintos tipos de distancia

- Distancia Euclídea
- Distancia de Manhattan
- Distancia Minkowski
- Distancia Mahalanobis
- Similitud de Coseno
- Distancia de Hamming
- Distancia de Jaccard



Distancia Euclídea

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} = \|\mathbf{x} - \mathbf{y}\|_2$$




La **distancia euclídea** es la métrica de distancia "ordinaria" entre dos puntos en un espacio n-dimensional. Se basa en el **Teorema de Pitágoras** y representa la longitud del segmento de línea recta que conecta esos dos puntos.

Es la distancia más corta posible entre dos objetos en un plano o espacio físico.

Distancia de Manhattan (L1)



$$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n |x_i - y_i| = \|\mathbf{x} - \mathbf{y}\|_1$$



También conocida como distancia del "taxista" o *city block*. En lugar de ir en línea recta, suma las diferencias absolutas de sus coordenadas.

Cuándo usarla: Es preferible a la Euclídea cuando se tienen datos con muchas dimensiones (**curse of dimensionality**) o cuando los valores atípicos (*outliers*) no deben tener un peso tan exagerado, ya que no eleva las diferencias al cuadrado.

Distancia Euclídea y distancia de Manhattan




Distancia Euclídea: es la distancia más corta posible entre dos puntos en un plano. En la imagen, corresponde a la **hipotenusa**.

Distancia Manhattan: Es la distancia recorrida siguiendo una cuadrícula o ejes perpendiculares. En la imagen, es la **suma de los dos catetos**.

Distancia Minkowski

$$\text{Minkowski Distance} = \left(\sum_{i=1}^n |x_i - y_i| \right)^{1/p}$$



Es una generalización de la Euclídea y la de Manhattan.


Uso: Si $p=1$, es Manhattan. Si $p=2$, es Euclídea. Si $p \rightarrow \infty$, se convierte en la distancia de Chebyshev. Te permite "tunear" la métrica según tus datos.

$$d(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}$$

Es una distancia "estadística". Mide la distancia de un punto a una distribución de puntos.

- **Clave:** Tiene en cuenta la **correlación** entre variables y es invariante a la escala.
- **Cuándo usarla:** Muy útil para detectar *outliers* y cuando las variables están altamente correlacionadas.

$$d_{\cos}(x, y) = 1 - \frac{x \cdot y}{\|x\| \cdot \|y\|}$$




No mide qué tan lejos están los puntos en el espacio, sino el **ángulo** entre dos vectores.

- **Rango:** De -1 a 1 (en minería de datos suele ser de 0 a 1).
- **Cuándo usarla:** Es el estándar para **Minería de Textos** (NLP). Si tienes dos documentos de longitudes diferentes pero que hablan del mismo tema, la distancia Euclídea dirá que son distintos (por la cantidad de palabras), pero el Coseno dirá que son similares (por la orientación del contenido).

Distancia de Hamming

$$d_H(x, y) = \sum_{i=1}^n \mathbb{I}(x_i \neq y_i)$$




Se utiliza específicamente para **variables categóricas**.

- **Cómo funciona:** Cuenta cuántas posiciones son diferentes entre dos hilos (strings) o vectores del mismo tamaño.
- **Ejemplo:** La distancia entre "caro" y "casa" es 1 (solo cambia la 'r' por la 's').
- **Cuándo usarla:** En genética (comparación de ADN) o cuando los datos de clustering son mayoritariamente etiquetas o binarios.

Distancia de Jaccard


$$d_J(X, Y) = 1 - \frac{|X \cap Y|}{|X \cup Y|}$$



Mide la similitud entre conjuntos.



- **Fórmula:** El tamaño de la intersección dividido por el tamaño de la unión de los conjuntos.
- **Cuándo usarla:** En sistemas de recomendación o cuando trabajas con datos binarios dispersos (*sparse data*). Por ejemplo: "Usuarios que compraron el producto A y el producto B".

Con el nombre de **clusterizado** ('clustering') se conoce a un conjunto de técnicas para **identificar clusters o agrupamientos en un dataset**. Un **clúster** es un **conjunto de muestras (individuos, casos, etc) que son más similares entre sí que las otras muestras que pertenecen a otros clústeres**.



Conceptualmente es similar a una clasificación. La diferencia radica en que cuando hacemos un método de clustering (clusterizado) no conocemos a priori a qué grupo pertenecen o pertenecerán los individuos en estudio.


Clusterizado de precipitaciones en Estados Unidos



<https://www.esri.com/arcgis-blog/products/arcgis-pro/analytics/end-to-end-spatial-data-science-1-clustering-us-precipitation-regions>


KMeans clustering

K-Means clustering




Tenemos un conjunto de datos en el cual deseamos encontrar posibles agrupaciones. Se asigna de manera arbitraria un centroide a cada cluster.

K-Means clustering




Luego de cada iteración ese centroide se mueve hacia la media del grupo en cuestión.

K-Means clustering




Este proceso se va repitiendo hasta que en una nueva iteración esos casos no se asignan a nuevos grupos, y el algoritmo se detiene. Notar que en la Figura, en la iteración 4 y 5 no se asignan a grupos nuevos las muestras en estudio.


Pasos de K-Means clustering




(a) original data



(b) iteration 1



(c) iteration 3



(d) iteration 5

Pasos del algoritmo K-Means


1. Seleccionar k (número de clústeres deseados).
2. El algoritmo inicializa de manera aleatoria en el espacio los k centroides.
3. Para cada caso/muestra/individuo:
 - Calcular la distancia entre ese centroide y cada muestra.
 - Asignar la muestra a su centroide más cercano.
4. Esos centroides se llevan a la media de cada grupo en estudio.
5. Se repiten los pasos 3 y 4 hasta que no ocurran cambios en los casos asignados a cada clúster, o se llegue a un número máximo de iteraciones.

Algorithm 10.1 *K-Means Clustering*

1. Randomly assign a number, from 1 to K , to each of the observations. These serve as initial cluster assignments for the observations.
 2. Iterate until the cluster assignments stop changing:
 - (a) For each of the K clusters, compute the cluster *centroid*. The k th cluster centroid is the vector of the p feature means for the observations in the k th cluster.
 - (b) Assign each observation to the cluster whose centroid is closest (where *closest* is defined using Euclidean distance).
-



Número de clusters óptimo

- Silhouette plots
- Método del codo (elbow method)



Para leer un poco más:

https://scikit-learn.org/stable/auto_examples/cluster/plot_kmeans_silhouette_analysis.html



Ventajas / Desventajas de K-Means Clustering

Ventajas

- Los grupos se asignan entre clusters hasta que un resultado estable se encuentra.
- Podría ser más rápido para implementar que otros algoritmos de clustering.
- Es relativamente simple de implementar


Desventajas

- No maneja variables categóricas.
- Sensible a datos en diferentes escalas.
- Sensible a outliers (datos extremos).
- Trata de encontrar clústeres esféricos de igual diámetro (los datos pueden no tener esa estructura).

Ventajas y desventajas de KMeans

Strengths	Weaknesses
• Uses simple principles that can be explained in non-statistical terms • Highly flexible and can be adapted with simple adjustments to address many of its shortcomings • Performs well enough under many real-world use cases	• Not as sophisticated as more modern clustering algorithms • Because it uses an element of random chance, it is not guaranteed to find the optimal set of clusters • Requires a reasonable guess as to how many clusters naturally exist in the data • Not ideal for non-spherical clusters or clusters of widely varying density

K-Means con datos espaciales





K-means clusters on a map

<https://wambualouis.medium.com/geospatial-machine-learning-101-exploring-k-means-clustering-with-geospatial-data-a69c6e475838>

Clustering Jerárquico


Clustering Jerárquico

Una potencial desventaja del clusterizado con KMeans es que requiere especificar el número de clústeres, K . **El clustering jerárquico es un enfoque alternativo que no requiere seleccionar de antemano K .** A su vez, nos proporciona una representación de las observaciones en forma de árbol, llamada **dendrograma**.




Clustering Jerárquico Aglomerativo vs Divisivo

Agglomerative Hierarchical Clustering



Divisive Hierarchical Clustering



Clustering jerárquico aglomerativo





Figure 3-33. Agglomerative clustering iteratively joins the two closest clusters



Clustering jerárquico aglomerativo

- *A diferencia del clusterizado de KMeans, el nombre sugiere el aprendizaje de clusters jerárquicos en un dataset.*
- *Nos ofrece un árbol en vez de una representación plana dentro de clusters.*
- *Como resultado, nos ofrece mayor entendimiento sobre agrupamientos complejos que pueden existir en un dataset (q KMeans).*
- *Gráficamente se lo asocia a un dendograma*




Dendograma mostrando un clustering de instrumentos en una orquesta.


Clustering jerárquico aglomerativo



2 grupos



3 grupos



Clustering jerárquico aglomerativo






Figure 3-35. Hierarchical cluster assignment (shown as lines) generated with agglomerative clustering, with numbered data points (cf. Figure 3-36)




Pasos

Nuestros datos




1 Se computa la matriz de distancias


B	15				
C	25	30			
D	40	19	20		
E	60	50	35	20	
F	62	55	40	25	5
	A	B	C	D	E



single-link



complete-link



average-link

2

Dendrograma teniendo en cuenta la distancia intra e inter grupos

Distintos tipos de 'linkage' en clustering

Definiciones

<i>Linkage</i>	<i>Description</i>
Complete	Maximal intercluster dissimilarity. Compute all pairwise dissimilarities between the observations in cluster A and the observations in cluster B, and record the <i>largest</i> of these dissimilarities.
Single	Minimal intercluster dissimilarity. Compute all pairwise dissimilarities between the observations in cluster A and the observations in cluster B, and record the <i>smallest</i> of these dissimilarities. Single linkage can result in extended, trailing clusters in which single observations are fused one-at-a-time.
Average	Mean intercluster dissimilarity. Compute all pairwise dissimilarities between the observations in cluster A and the observations in cluster B, and record the <i>average</i> of these dissimilarities.

Distintos tipos de 'linkage' en clustering





Figure 17.3 Different linkage methods to define the distance between clusters. Centroid linkage calculates the distance between cluster centroids. Single linkage calculates the smallest distance between clusters. Complete linkage calculates the largest distance between clusters. Average linkage calculates all pairwise distances between cases in two clusters and finds the mean. Ward's method calculates the within-cluster sum of squares for each candidate merge and chooses the one with the smallest value.

Distintos tipos de 'linkage'





Algorithm 10.2 *Hierarchical Clustering*

1. Begin with n observations and a measure (such as Euclidean distance) of all the $\binom{n}{2} = n(n-1)/2$ pairwise dissimilarities. Treat each observation as its own cluster.
 2. For $i = n, n-1, \dots, 2$:
 - (a) Examine all pairwise inter-cluster dissimilarities among the i clusters and identify the pair of clusters that are least dissimilar (that is, most similar). Fuse these two clusters. The dissimilarity between these two clusters indicates the height in the dendrogram at which the fusion should be placed.
 - (b) Compute the new pairwise inter-cluster dissimilarities among the $i-1$ remaining clusters.
-


Ejemplo de aplicación

- Clusterización de crímenes en Ottawa




DBSCAN

DBSCAN (**Density-Based Spatial Clustering of Applications with Noise**) es uno de los algoritmos de clustering más potentes y utilizados, especialmente cuando los datos no tienen formas esféricas o contienen mucho "ruido" (puntos que no pertenecen a ningún grupo). DBSCAN es un algoritmo de **clustering basado en densidad** que define los grupos como subconjuntos maximales de puntos conectados por densidad.




La diferencia fundamental es que **K-means** es un algoritmo **basado en centroides** que asume que los clusters tienen formas esféricas y requiere definir de antemano el número de grupos (\$k\$), mientras que **DBSCAN** es un algoritmo **basado en densidad** que descubre el número de clusters automáticamente, permitiendo identificar formas arbitrarias (no convexas) y separando eficazmente el ruido o los *outliers* del resto de los datos.



DBSCAN determina la densidad de un área basándose en dos parámetros proporcionados al algoritmo:

- Épsilon (ϵ): El radio de la vecindad alrededor de un punto de datos.
- MinPts (Puntos Mínimos): El número mínimo de puntos de datos que deben estar dentro del radio ϵ de un punto dado.



En función de estos dos parámetros, el algoritmo diferencia tres tipos de puntos de datos:

Punto central: Un punto de datos que tiene al menos MinPts dentro de una distancia ϵ (incluido él mismo).

Punto límite: Un punto de datos que tiene menos de MinPts dentro de una distancia ϵ , pero se encuentra dentro de una distancia ϵ de un punto central.

Punto de ruido (valor atípico): Cualquier punto de datos que no sea un punto central ni un punto límite.

El éxito de DBSCAN depende casi exclusivamente de estos dos valores:

ϵ (Epsilon)

Es la distancia máxima para considerar a dos puntos como vecinos.

- **Si es muy pequeño:** Gran parte de los datos se marcará como ruido y los clusters reales se fragmentarán.
- **Si es muy grande:** Los clusters se fusionarán en uno solo (efecto "puente").
- **Tuning:** Se recomienda el **K-Distance Graph**. Se calcula la distancia de cada punto a su k-ésimo vecino más cercano (donde $k = \text{MinPts}$), se grafican en orden ascendente y se busca el "codo" de la curva.

MinPts (Minimum Points)

Es el umbral de densidad.

- **Regla general:** $\text{MinPts} \geq \text{dimensiones} + 1$. Para datos en 2D, el mínimo suele ser 4.
- **Datos con ruido:** Si tus datos tienen muchos "outliers" o errores de medición, aumenta este valor (ej. 10 o 20) para evitar que el ruido forme clusters falsos.

DBSCAN




Figure 18.2 The DBSCAN algorithm. A case is selected at random, and if its *epsilon* radius (ϵ) contains *minPts* cases, it is considered a core point. Reachable cases of this core point are evaluated the same way until there are no more reachable cases. This network of density-connected cases is considered a cluster. Cases that are reachable from core points but are not themselves core points are border points. The algorithm moves on to the next unvisited case. Cases that are neither core nor border points are labeled as noise.

VENTAJAS


- **No requiere definir K:** A diferencia de K-Means, el algoritmo descubre el número de clusters por sí mismo basándose en la densidad de los datos.
- **Formas arbitrarias:** Es capaz de encontrar clusters con formas complejas (como anillos, lunas o líneas entrelazadas) donde los algoritmos basados en distancias al centroide fallan.
- **Robustez frente al ruido:** Es uno de los pocos algoritmos que identifica y separa explícitamente los *outliers*, evitando que estos distorsionen la estructura de los grupos.
- **Hiperparámetros físicos:** Los hiperparámetros (ϵ y *MinPts*) tienen un significado físico intuitivo relacionado con la densidad, lo cual facilita su explicación teórica.

DESVENTAJAS

- **Densidades variables:** Si el dataset tiene clusters con densidades muy diferentes (algunos muy compactos y otros muy dispersos), es casi imposible encontrar un único valor de ϵ que funcione para todos.
- **Sensibilidad a los hiperparámetros:** Pequeños cambios en el valor de ϵ pueden provocar que clusters independientes se fusionen o que puntos válidos se marquen como ruido.
- **La maldición de la dimensionalidad:** En espacios de alta dimensión, los datos tienden a ser dispersos y la noción de "densidad" se vuelve difusa, lo que degrada la precisión del algoritmo.
- **Dependencia del orden:** Aunque los puntos núcleo y ruido suelen ser constantes, los puntos frontera pueden cambiar de un cluster a otro dependiendo del orden en que se procesen los datos.

Característica	K-Means	DBSCAN	Clustering Jerárquico
Paradigma	Basado en centroides	Basado en densidad	Basado en conectividad (árbol)
Forma de los clusters	Esféricas (convexas)	Arbitrarias	Depende del enlace (<i>linkage</i>)
Número de grupos	Debe definirse (k)	Lo descubre sólo	Se elige al cortar el dendrograma
Manejo de Outliers	Muy sensible (los incluye)	Excelente (los identifica)	Sensible (pueden formar ramas)
Escalabilidad	Muy alta ($O(n)$)	Media ($O(n \log n)$)	Baja ($O(n^2)$ o $O(n^3)$)
Interpretación	Fácil (centros de masa)	Media (zonas densas)	Visual (dendrograma)

DBSCAN para detectar centros de actividad urbana



Paper (DBSCAN junto a otros métodos)

https://www.researchgate.net/publication/333912582_Urban_Crowd_Detection_Using_SOM_DBSCAN_and_LBSN_Data_Entropy_A_Twitter_Experiment_in_New_York_and_Madrid

<https://bitsandbricks.github.io/post/dbscan-machine-learning-para-detectar-centros-de-actividad-urbana/>

HDBSCAN

HDBSCAN es un algoritmo que extiende a DBSCAN convirtiéndolo en un algoritmo de **clustering jerárquico**. En lugar de buscar una densidad "umbral" fija (como el ϵ de DBSCAN), HDBSCAN realiza una exploración sobre todos los valores posibles de epsilon y extrae los clusters que son más **estables** a lo largo de la jerarquía. Esencialmente, es "DBSCAN aplicado a todos los niveles de densidad".




HDBSCAN (Agrupación Espacial Basada en Densidad Jerárquica de Aplicaciones con Ruido, por sus siglas en inglés) es un algoritmo de *clustering* avanzado que mejora significativamente a su predecesor, DBSCAN, al resolver su mayor limitación: la dificultad para identificar clusters de diferentes densidades.

HDBSCAN no busca clústeres en un único nivel de densidad global, sino que construye una jerarquía completa de clústeres y extrae los más estables.

Lo hace a través de los siguientes pasos:

- **Transformación del espacio (Distancia de Alcanzabilidad Mutua):** Primero, el algoritmo calcula la **distancia central** (*core distance*) de cada punto, que es la distancia hacia su k -ésimo vecino más cercano (el valor de k lo define el parámetro `min_samples`). Luego, calcula la **distancia de alcanzabilidad mutua** entre cualquier par de puntos a y b usando la fórmula: `max(core_distance(a), core_distance(b), distance(a, b))`. Esto tiene un efecto matemático crucial: aleja los puntos dispersos (ruido) y mantiene cercanos los puntos en áreas densas.
- **Construcción del Árbol de Expansión Mínima (MST):** Con estas nuevas distancias, el algoritmo utiliza el algoritmo de Prim para construir un grafo que conecta todos los puntos con el menor peso posible, formando un Árbol de Expansión Mínima.

- **Construcción de la Jerarquía de Clústeres:** Ordena las conexiones (aristas) del MST de menor a mayor peso y comienza a fusionar puntos iterativamente. Esto crea una jerarquía de fusiones que suele visualizarse como un **dendrograma**. Las fusiones tempranas representan regiones de alta densidad, mientras que las tardías representan regiones de baja densidad.
- **Condensación del árbol:** Los dendrogramas en bruto son muy complejos. HDBSCAN simplifica esta jerarquía utilizando un parámetro fundamental: `min_cluster_size` (tamaño mínimo del clúster). Al recorrer el árbol, si un clúster se divide en partes más pequeñas que este tamaño mínimo, los puntos pequeños se consideran "ruido" que se cayó del clúster, y solo el clúster grande mantiene su identidad.
- **Extracción de Clústeres (Evaluación de Estabilidad):** En lugar de establecer un umbral arbitrario para cortar el árbol, HDBSCAN elige los clústeres que son más "estables" frente a los cambios de densidad. Calcula un puntaje de estabilidad observando el λ_{birth} (cuando se forma el clúster) y el λ_{death} (cuando un punto se sale del clúster). Los clústeres que "viven" más tiempo en la jerarquía sin dividirse se seleccionan como los clústeres finales.





Cálculo de la Core Distance

La **Core Distance** es el radio necesario para que un círculo alrededor de un punto contenga exactamente k vecinos.


- **Paso 1 (Azul):** El punto está en una zona densa. El círculo es pequeño porque encuentra a sus 5 vecinos rápidamente. Su *Core Distance* es corta.
- **Paso 2 (Verde):** El punto está más alejado. El círculo debe expandirse mucho más para alcanzar a los 5 vecinos. Su *Core Distance* es larga.
- **Paso 3 (Roja):** Muestra un tercer punto con una densidad intermedia.

Pasos de HDBSCAN




Distancia de alcanzabilidad mutua

Pasos de HDBSCAN



Creación de árbol





Creación de dendrograma

- **No requiere adivinar la cantidad de clústeres:** A diferencia de K-Means, que requiere que predefinas el número k de agrupaciones, HDBSCAN descubre el número óptimo por sí mismo basándose en la estructura de los datos.
- **Se adapta a formas y densidades variables:** Mientras K-Means asume clústeres esféricos y DBSCAN asume densidad uniforme, HDBSCAN detecta grupos naturales sin importar si tienen formas irregulares, alargadas o densidades dispares.
- **Excelente filtrado de ruido:** No obliga a todos los puntos a pertenecer a un clúster. Si un punto es una anomalía o ruido, simplemente lo clasifica como tal, lo cual es vital para limpiar datos del mundo real o para detección de fraudes.
- **Hiperparámetros intuitivos:** Su parámetro principal, `min_cluster_size`, es muy intuitivo ya que simplemente le dice al algoritmo cuál es el tamaño de grupo más pequeño que consideras relevante.

Comparativa

Característica	K-Means	Jerárquico (Aglomerativo)	DBSCAN	HDBSCAN
Tipo de Modelo	Basado en centroides	Basado en conectividad	Basado en densidad	Basado en densidad jerárquica
Forma de los Grupos	Solo esféricos / convexos	Variable (según enlace)	Arbitraria / Compleja	Arbitraria y Variable
Requiere definir k	Sí (obligatorio)	No (se corta el árbol)	No	No
Manejo de Outliers	Muy sensible (los incluye)	Los incluye en ramas	Los identifica como ruido	Excelente manejo de ruido
Densidades	Asume densidad uniforme	No maneja densidades bien	Solo una densidad fija	Maneja densidades múltiples
Complejidad / Escala	Muy eficiente $O(n)$	Ineficiente $O(n^2)$ o $O(n^3)$	Eficiente $O(n \log n)$	Moderada $O(n \log n)$

Geographic clustering with HDBSCAN



<https://medium.com/data-science/geographic-clustering-with-hdbscan-ef8cb0ed6051>

Métricas

Métricas intrínsecas

- Silhouette Coefficient
- Davies - Bouldin Index

No conozco previamente las etiquetas

Métricas extrínsecas

- Homogeneidad
- Completitud
- V-measure
- Adjusted Rand Index (ARI)
- Adjusted Mutual Information (AMI)

Si conozco las etiquetas

El coeficiente de silueta se calcula utilizando la distancia media intraclúster (a) y la distancia media al clúster más cercano (b) para cada muestra.

El coeficiente de silueta para una muestra es $(b - a) / \max(a, b)$. Para mayor claridad, b es la distancia entre una muestra y el clúster más cercano al que no pertenece. Cabe destacar que el coeficiente de silueta solo se define si el número de etiquetas es $2 \leq n_{\text{etiquetas}} \leq n_{\text{muestras}} - 1$.

Puntuación: de -1 a 1.

El mejor valor es 1 y el peor es -1. Los valores cercanos a 0 indican clústeres superpuestos. Los valores negativos generalmente indican que una muestra se ha asignado al clúster incorrecto, ya que otro clúster es más similar.

La puntuación se define como la medida de similitud promedio de cada clúster con su clúster más similar, donde la similitud es la relación entre las distancias dentro de cada clúster y las distancias entre clústeres. Por lo tanto, los clústeres más distantes y menos dispersos obtendrán una mejor puntuación.

Puntuación:

La puntuación mínima es cero, y los valores más bajos indican una mejor agrupación.

Un resultado de agrupamiento cumple con el criterio de homogeneidad si todos sus clústeres contienen únicamente puntos de datos que pertenecen a una sola clase.

Esta métrica es independiente de los valores absolutos de las etiquetas: una permutación de los valores de las etiquetas de clase o clúster no modificará el valor de la puntuación.

Puntuación: de 0 a 1.

siendo 1 cuando son perfectamente homogéneos.

Calcula la métrica de completitud de un etiquetado de clústeres a partir de una verdad fundamental.

Un resultado de agrupamiento cumple con la completitud si todos los puntos de datos que pertenecen a una clase determinada son elementos del mismo clúster.

Esta métrica es independiente de los valores absolutos de las etiquetas: una permutación de los valores de las etiquetas de clase o clúster no modificará el valor de la puntuación.

Puntuación: de 0 a 1.

siendo 1 cuando son perfectamente completo.

La medida V es la media armónica entre homogeneidad y completitud.

Esta métrica es independiente de los valores absolutos de las etiquetas: una permutación de los valores de las etiquetas de clase o clúster no modificará el valor de la puntuación.

Además, esta métrica es simétrica: intercambiar `label\_true` por `label\_pred` dará como resultado el mismo valor de puntuación. Esto puede ser útil para medir la concordancia de dos estrategias independientes de asignación de etiquetas en el mismo conjunto de datos cuando se desconoce la verdad fundamental.

Puntuación: de 0 a 1.

siendo 1 cuando son perfectamente completo.

Adjusted Rand Score

El Rand index calcula una medida de similitud entre dos agrupaciones considerando todos los pares de muestras y contando los pares que se asignan al mismo o a diferentes grupos en las agrupaciones predichas y reales.

La puntuación RI raw se "ajusta por azar" para obtener la puntuación ARI utilizando el siguiente esquema:

$$ARI = (RI - Expected_RI) / (max(RI) - Expected_RI)$$

De este modo, se garantiza que el índice de Rand ajustado tenga un valor cercano a 0 para el etiquetado aleatorio, independientemente del número de clústeres y muestras, y exactamente 1 cuando los clústeres son idénticos.

Adjusted Mutual Information (AMI)



La Información Mutua Ajustada (AMI) es un ajuste de la puntuación de Información Mutua (IM) para tener en cuenta el azar. Considera que la IM suele ser mayor para dos agrupaciones con un mayor número de clústeres, independientemente de si realmente se comparte más información.

Puntuación: de 0 a 1.

siendo 1 cuando dos grupos son idénticos. Las particiones aleatorias tienen un valor cercano a 0.

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.adjusted_mutual_info_score.html

- <https://medium.datadriveninvestor.com/hdbscan-explained-a-beginners-guide-to-density-based-clustering-69395ca8cc91>
- <https://medium.com/@ujangriswanto08/what-is-hdbscan-an-evolution-of-dbscan-for-complex-data-clustering-cccb1a7aac8>
- <https://ujangriswanto08.medium.com/how-hdbscan-outperforms-traditional-clustering-methods-in-real-world-scenarios-18f812e7e759>
- https://hdbscan.readthedocs.io/en/latest/how_hdbscan_works.html
- <https://mbrenndoerfer.com/writing/hdbscan-hierarchical-density-based-clustering-automatic-cluster-selection>
- <https://arize.com/blog-course/understanding-hdbscan-a-deep-dive-into-hierarchical-density-based-clustering/>

- Burkov, A. *The Hundred-page ML Book*
- Gareth, J. *Introduction to statistical learning.*
- Raschka, S & Mirjalili, V. *Python Machine Learning.*