

Unidad 10

Taxonomía de la Interpretabilidad: Métodos intrínsecos (modelos simples) vs. *post-hoc* (modelos complejos). Métodos globales vs. locales. Métodos Agnósticos al Modelo: Feature Importance: Importancia por permutación. Partial Dependence Plots (PDP): Visualización del efecto marginal de una característica. LIME (Local Interpretable Model-agnostic Explanations): Explicaciones locales mediante modelos sustitutos lineales. Teoría de Juegos Aplicada: SHAP (SHapley Additive exPlanations): Concepto de valores de Shapley. Ventajas de SHAP sobre otros métodos de importancia de variables. Interpretabilidad en Redes Neuronales: Mapas de activación y Saliency Maps.

Generalidades

La IA explicable, también conocida como *XAI*, es un campo del aprendizaje automático (ML) que comprende técnicas cuyo objetivo es comprender mejor el comportamiento de los modelos, proporcionando explicaciones sobre cómo un modelo realizó una predicción.

Conocer el comportamiento de un modelo y cómo influye en él su conjunto de datos de entrenamiento otorga a quienes desarrollan o utilizan aprendizaje automático nuevas y poderosas capacidades para mejorar los modelos, aumentar la confianza en sus predicciones y comprender cuándo surgen problemas.

Las técnicas de IA explicable son especialmente útiles porque no dependen de un modelo específico: una vez que se conoce un método de IA explicable, se puede utilizar en diversos escenarios.

La IA explicable se basa en la creación de explicaciones, es decir, en la capacidad de explicar un modelo. La capacidad de explicar implica que las acciones de un modelo pueden describirse en términos comprensibles para quien utilice las predicciones del modelo de aprendizaje automático.

Esta capacidad de explicar cumple **diversas funciones**, desde mejorar la calidad del modelo hasta generar confianza e incluso proporcionar una vía de corrección cuando una predicción no coincide con lo esperado.

A medida que hemos desarrollado modelos cada vez más complejos, hemos descubierto que un modelo de alto rendimiento no es suficiente para ser aceptable en el mundo real. Es necesario que una predicción también cuente con una explicación razonable y que, en general, el modelo se comporte según lo previsto por sus creadores.




Figure 9.3 Scope of explainable AI (XAI)

¿Quién necesita la explicabilidad?



Profesionales

Científicos de datos e ingenieros familiarizados con el aprendizaje automático


Observadores

Partes interesadas del negocio y reguladores con cierto conocimiento del aprendizaje automático, pero que se preocupan principalmente por la función y el rendimiento general del sistema de aprendizaje automático

Usuarios finales

Expertos en el dominio y usuarios afectados que pueden tener poco o ningún conocimiento del aprendizaje automático, y que también reciben los resultados del sistema de aprendizaje automático

Explicabilidad e interpretabilidad






Figure 2-1. Explainability and interpretability are two ends of a spectrum. Here we show key characteristics of techniques at each end of the spectrum, and show some examples of where techniques fall along this spectrum.

Tipos de técnicas de interpretabilidad

- Interpretabilidad intrínseca vs. interpretación post-hoc: La distinción entre interpretabilidad intrínseca y post-hoc se basa en si la transparencia es una propiedad inherente al diseño del modelo o si se deriva de un análisis posterior al entrenamiento.
- Específicas del modelo vs. agnósticos del modelo: Los métodos agnósticos al modelo son herramientas potentes porque no dependen de los parámetros internos o la arquitectura del algoritmo utilizado. Se basan únicamente en la manipulación de las entradas y la observación de los cambios en las salidas del modelo.
- Interpretabilidad global vs. interpretabilidad local: El alcance define si la técnica busca explicar el comportamiento general del modelo en todo el conjunto de datos o si se centra en una sola predicción específica.

Interpretabilidad intrínseca vs interpretabilidad post-hoc

Las técnicas de **interpretabilidad intrínseca** se relacionan con los modelos de aprendizaje automático de estructura simple, también llamados modelos de caja blanca. Los modelos de caja blanca son inherentemente transparentes, y la interpretación de su funcionamiento interno es sencilla. La interpretabilidad surge de forma natural en estos modelos.

Las técnicas de **interpretabilidad post hoc** se suelen aplicar después del entrenamiento del modelo y se utilizan para interpretar y comprender la importancia de ciertas entradas para la predicción del modelo. Estas técnicas son adecuadas tanto para modelos de caja blanca como de caja negra, es decir, modelos que no son inherentemente transparentes.

Interpretabilidad intrínseca vs interpretabilidad post-hoc

Atributo	Interpretabilidad Intrínseca	Interpretabilidad Post-hoc
Arquitectura	Simple, transparente por diseño.	Compleja (Caja Negra).
Momento de Aplicación	Durante la fase de entrenamiento/diseño.	Después del entrenamiento (despliegue).
Fidelidad de la Explicación	Exacta (el modelo es la explicación).	Aproximada (se basa en sustitutos o perturbaciones).
Ejemplos	Regresión lineal, árboles cortos.	LIME, SHAP, Saliency Maps.
Carga Computacional	Generalmente baja.	Puede ser muy alta (requiere múltiples inferencias).

Técnicas específicas del modelo vs técnicas agnósticas del modelo

Las técnicas de interpretabilidad pueden ser **específicas del modelo (model specific)** o **independientes del modelo (model agnostic)**.

Las técnicas de interpretabilidad específicas del modelo (model specific), como su nombre indica, solo se pueden aplicar a ciertos tipos de modelos. Las técnicas de interpretabilidad intrínsecas son específicas del modelo por naturaleza, ya que están ligadas a la estructura específica del modelo utilizado.

Sin embargo, las técnicas de interpretabilidad independientes del modelo no dependen del tipo específico de modelo. Se pueden aplicar a cualquier modelo porque son independientes de su estructura interna. Las técnicas de interpretabilidad a posteriori son, en su mayoría, independientes del modelo.

Técnicas de interpretabilidad local vs global

Métodos Globales

La interpretabilidad global intenta desentrañar la lógica completa del modelo, permitiendo a los usuarios comprender qué características son generalmente importantes y cómo influyen en las predicciones en promedio. Estos métodos son cruciales para el desarrollo de modelos, ya que ayudan a identificar sesgos en el conjunto de datos y a realizar una selección de variables informada. Técnicas como la Importancia por Permutación o los Gráficos de Dependencia Parcial (PDP) son ejemplos destacados de este enfoque.

Métodos Locales

La interpretabilidad local se centra en explicar una predicción individual, respondiendo a la pregunta: "¿Por qué el modelo tomó esta decisión específica para este caso particular?". Este enfoque es crítico en aplicaciones de alto riesgo, como el diagnóstico médico o la aprobación de créditos, donde la justificación individual es un requisito ético o legal. Métodos como LIME y los valores de Shapley individuales proporcionan este nivel de detalle granular.

Técnicas de interpretabilidad local vs global

Las técnicas de interpretabilidad pueden tener un alcance local o global.

Las técnicas de interpretabilidad local buscan comprender mejor la predicción del modelo para un caso o ejemplo específico.

Por otro lado, las técnicas de interpretabilidad global buscan comprender mejor el modelo en su conjunto: los efectos globales de las características de entrada en la predicción del modelo.




Figure 1.14 Types of interpretability techniques

La interpretabilidad intrínseca significa que **las explicaciones forman parte de la propia arquitectura y predicción del modelo**. Estos métodos se relacionan con modelos que tienen una estructura algorítmica y matemática sencilla, lo que los hace inherentemente transparentes (modelos *white-box*).

Características principales:

- **Transparencia inherente:** El proceso de aprendizaje es directo y permite ver claramente cómo las características de entrada (features) se transforman en la variable objetivo.
- **Explicaciones directas:** La importancia de las variables se puede deducir directamente de los componentes del modelo. Por ejemplo, en una regresión lineal, la explicación intrínseca son simplemente los coeficientes o pesos asignados a cada característica. En un árbol de decisión, la explicación es la serie de puntos de decisión (nodos) que conducen al resultado final.

Ejemplos de modelos de caja blanca




Table 2.1 Mapping of a white-box model to a machine learning task

White-box model	Machine learning task(s)
Linear regression	Regression
Logistic regression	Classification
Decision trees	Regression and classification
GAMs	Regression and classification

Figure 2.2 White-box models on the interpretability versus predictive power plane

Ventajas:

- Son fáciles de entender y explicar a audiencias no técnicas o partes interesadas (stakeholders) del negocio.
- Además, al ser la interpretabilidad un subproducto del cálculo interno, casi no requieren tiempo computacional adicional para generar la explicación.

Desventajas:

Por lo general, **tienen un poder predictivo bajo a medio**. A menudo no logran modelar relaciones no lineales complejas de manera óptima, lo que puede llevar a problemas de subajuste (underfitting) o, en el caso de árboles muy profundos, a sobreajuste (overfitting) perdiendo su transparencia.

Los métodos post-hoc **se aplican después de que el modelo ha sido entrenado y dependen de las predicciones resultantes para crear la explicación.** Se utilizan principalmente para modelos complejos, conocidos como cajas negras (*black-box*), cuyas operaciones matemáticas internas involucran millones de parámetros o divisiones de datos, lo que hace imposible comprenderlos a simple vista.

Características principales:

- **Desacoplamiento:** Tienen poca o ninguna visibilidad de los cálculos internos del modelo. En cambio, generan explicaciones simulando muchas predicciones con varias combinaciones de características de entrada para observar cómo cambia el resultado.
- **Alto poder predictivo:** Permiten a los ingenieros de ML utilizar algoritmos altamente precisos y sofisticados para tareas críticas (como visión por computadora o procesamiento de lenguaje natural) sin sacrificar por completo la transparencia.

Ejemplos de modelos Post-hoc




Table 2.3 Mapping of black-box model to machine learning tasks

Black-box model	Machine learning tasks
Tree ensembles (random forest, gradient-boosted trees)	Regression and classification
Deep neural networks (DNNs)	Regression and classification
Convolutional neural networks (CNNs)	Image classification, object detection
Recurrent neural networks (RNNs)	Sequence modeling, language understanding

Figure 2.23 Black-box models on the interpretability versus predictive power plane

Resumen de métodos

Tipos de datos

- Datos tabulares
- Texto
- Imágenes

Table A-1. Summary of explainable techniques applicable to tabular models

Technique	What to know	Pros	Cons
Feature permutation	Changes the value of input features to observe how the model's score changes	• Easy to implement • Intuitive	• Highly correlated features are misleading • Does not reflect the actual predictive value of a feature
Shapley values	Uses game theory to determine feature attributions	• Can be used for global, cohort, and local explanations • Intuitive	• Computationally intensive • Choosing baseline can be hard • Actual process of calculating Shapley values can be difficult to explain to stakeholders and end users

Technique	What to know	Pros	Cons
Decision tree	Explanations based directly on weights in tree nodes	• Easy to understand • Computationally trivial	• Scikit solution does not support multilabel classification
Partial dependence plots (PDPs)	Shows marginal effect of specific feature in a prediction	• Easy to implement • Can indicate a causal relationship if no feature correlation	• Assumes features are independent • Lack of values for a feature causes reliability issues
Individual conditional explanations (ICE)	Extension of PDPs to visualize feature dependence per instance	• Gives more holistic view than PDPs	• Same issues as PDPs • Visualizations can quickly become unreadable
Accumulated local effects (ALE)	Extends PDPs to account for correlated features	• Accounts for conditional dependence of correlated features • Good OSS options for visualizing	• Implementation not intuitive • Strongly correlated features can still cause issues

Table A-2. Summary of explainable techniques applicable to image models

Technique	What to know	Pros	Cons
Integrated Gradients (IG)	Local pixel attribution method based on sampling image along gradient of values	• Intuitive explanations • Among faster image explanation techniques	• Requires model to be differentiable • Sensitive to baseline
XRAI	Region-based attribution method based on IG	• Faster than other region-based techniques • Works best on natural images	• Only useful for image models • Less granular explanations
Grad-CAM	Popular region-based attribution method; use Grad-CAM++, if at all	• Computationally efficient	• Flawed explanations • Prone to identifying background as relevant

Technique	What to know	Pros	Cons
LIME	Primarily for classification models, pixel-based attributions	• Popular • Many visualization options	• Explanations are brittle and can be low accuracy • Prone to identifying background as relevant • Slow
Guided Backprop and Guided Grad-CAM	Build on DeConvNets, which examine the interior layers of a convolution network	• Sharper visualizations • Localize relevant regions	• Some research suggests they fail basic “sanity” checks

Tipo de dato: Texto

Table A-3. Summary of explainable techniques applicable to text models

Technique	What to know	Pros	Cons
LIME	Perturbs input by randomly removing words, and works best with ~1K perturbations	• Easy to implement • Model agnostic	• Very sensitive parameters related to kernel width • Does not work well for highly nonlinear models
Gradient x Input	Saliency method for word tokens that allows positive and negative attributions	• Easy and fast to implement • Research indicates best performing explainability technique for transformers	• Only works for differentiable models • Should be used in conjunction with other gradient-based techniques
Layer Integrated Gradients	Variation of Integrated Gradients (IG), but focused on a single layer of the network instead of input features	• Useful for text to isolate the embedding layer • Same pros as IG	• Same cons as IG
Layer-Wise Relevance Propagation (LRP)	Accumulates influence from layers in model from head back toward inputs	• Very modular and widely usable • Good performance for text classification	• Only works with DNNs • Attributions can concentrate on only a few features


Tipo de dato	Métodos
Datos tabulares	Feature permutation SHAP values Árboles de decisión PDPs ICE ALE
Imágenes	Integrated Gradients XRAI GradCam LIME Guided Backprop & Guided GradCam
Texto	LIME Gradient x Input Layer Integrated Gradients Layer-wise relevance propagation

Feature importance permutation (FIP)

Permutation Feature Importance

La Importancia de Características por Permutación (Permutation Feature Importance) es un método global que cuantifica la relevancia de una variable midiendo cuánto disminuye el rendimiento del modelo cuando los valores de dicha variable se barajan aleatoriamente.

El principio subyacente es intuitivo: si una característica es importante para el modelo, romper la relación entre esa característica y el objetivo real (target) mediante la permutación debería causar un aumento significativo en el error de predicción.



El algoritmo sigue estos pasos:

1. Se entrena el modelo y se calcula una métrica de error base (e_{orig}) sobre un conjunto de datos (preferiblemente un conjunto de prueba para evaluar la generalización).
2. Para cada característica $j \in \{1, \dots, p\}$:
 - Se genera una matriz de datos permutada $X_{perm,j}$ barajando aleatoriamente los valores de la característica j .
 - Se calcula el error del modelo sobre estos datos permutados ($e_{perm,j}$).
 - Se define la importancia como el cociente $FI_j = e_{perm,j} / e_{orig}$ o la diferencia $FI_j = e_{perm,j} - e_{orig}$.
3. Se ordenan las características por su valor de importancia descendente.

El problema de la independencia y la correlación

Una limitación crítica de PFI es que asume que las características son independientes. Cuando existen características altamente correlacionadas, la permutación de una de ellas puede crear instancias de datos "irreales" o físicamente imposibles en el espacio de características.

Por ejemplo, si el modelo predice el precio de una vivienda basándose en el "número de habitaciones" y la "superficie total", permutar solo la superficie podría generar un punto de datos donde una casa tiene 10 habitaciones pero solo 20 metros cuadrados. El modelo, al ser evaluado en estas regiones fuera de la distribución (out-of-distribution), puede producir resultados engañosos, diluyendo la importancia real de las variables involucradas.

Partial dependence Plots (PDPs)


Mientras que la importancia por permutación nos dice *cuánto* importa una variable, los Gráficos de Dependencia Parcial (PDP) nos dicen **cómo influye exactamente esa variable en el resultado**. Son una herramienta visual, global y agnóstica del modelo.

¿Cómo funciona? Un PDP visualiza el **efecto marginal o promedio** que tiene una característica específica sobre el resultado predicho por el modelo. Para ello, toma un valor específico de la característica que estamos analizando, fuerza a que todos los ejemplos del conjunto de datos tengan ese valor exacto, y calcula el valor promedio de las predicciones resultantes. Al repetir esto a lo largo de todos los valores posibles de la característica, obtenemos una curva.

Interpretación de PDPs

La **PDP (Partial Dependence Plot)** representa el **efecto promedio** que tiene la edad sobre la predicción del modelo, manteniendo todas las demás variables constantes.

- **De 0 a 10 años (El "Efecto Niños"):** La curva comienza en su punto más bajo (alrededor de 0.40) para los recién nacidos y sube rápidamente hasta aproximarse a 0.50-0.55 cerca de los 10 años. Esto significa que, en promedio, a medida que pasamos de bebés a niños, el modelo le asigna una probabilidad de supervivencia ligeramente mayor o creciente en ese tramo inicial.
- **De 15 a 45 años (La Meseta de los Adultos):** Aquí la línea promedio se estabiliza y oscila de forma "serruchada" entre **0.50 y 0.60**. Hay un par de caídas notables (por ejemplo, cerca de los 28-30 años), lo que indica que en esos rangos específicos de edad el modelo ve un leve impacto negativo en la supervivencia general, pero se mantiene bastante plano en el gran esquema.
- **Mayores de 55 años:** La línea vuelve a subir levemente y se estabiliza por encima de 0.60. Esto sugiere que para el modelo, las personas mayores de esa edad (en promedio) mantenían una predicción de supervivencia relativamente alta y constante en comparación con los adultos jóvenes.




Al igual que PFI, el PDP sufre gravemente ante la presencia de correlaciones fuertes entre variables. Debido a que el método promedia la salida sobre la distribución marginal, ignora las dependencias estructurales, lo que lleva nuevamente a la evaluación del modelo en regiones de datos improbables. Esto puede resultar en una visualización que no representa fielmente el comportamiento del modelo en el mundo real.

Individual Conditional Explanations (ICE)

Definición de ICE Plots Los gráficos ICE son una técnica de explicabilidad *post-hoc*, *agnóstica del modelo* y de naturaleza *local* que **visualiza la dependencia y el efecto que tiene una característica (feature) específica sobre la predicción del modelo para cada instancia individual en el conjunto de datos.**


- Mientras que un PDP muestra el efecto **promedio o global** de una variable en todo el conjunto de datos, un gráfico ICE desglosa esa información mostrando **una línea separada para cada uno de los ejemplos individuales.**
- De hecho, la línea del PDP es simplemente el promedio matemático de todas las líneas individuales que componen un gráfico ICE.



Interpretación ICE Plots

Para entender bien la PDP, hay que mirar el "caos" de líneas azules que tiene de fondo:

- Las líneas individuales (**ICE**) muestran que el comportamiento **no es igual para todos**.
- Hay un grupo enorme de líneas azules que se quedan pegadas abajo en **0.0** (gente que el modelo predice que va a fallecer sí o sí, probablemente hombres de tercera clase).
- Otro grupo enorme de líneas se queda pegado arriba en **1.0** (gente que el modelo predice que se salvará seguro, probablemente mujeres de primera clase).
- Como hay tantas líneas yendo por extremos opuestos, la línea naranja (PDP) simplemente hace un **promedio** de ambas realidades. Por eso se mantiene flotando en el medio (alrededor de 0.5 - 0.6).



Ventajas de los ICE Plots:

- **Revelan la heterogeneidad (interacciones ocultas):** Este es su mayor beneficio. Al promediar los datos, un PDP puede ocultar relaciones complejas. Por ejemplo, un PDP podría mostrar que a medida que aumenta la edad de una casa, su valor promedio disminuye; sin embargo, al ver las líneas ICE, podrías descubrir que para un subgrupo específico, el valor en realidad aumenta.
- **Visión holística:** Permiten al usuario ver el comportamiento exacto del modelo a nivel de ejemplo individual en lugar de conformarse con un agregado estadístico

Desventajas y Limitaciones:

- **Gráficos abarrotados (Efecto "Espagueti"):** Al dibujar una línea por cada instancia del conjunto de datos, si tienes miles de ejemplos, el gráfico se vuelve rápidamente ruidoso, saturado y muy difícil de leer. Por ello, a menudo se grafica solo una muestra aleatoria de las instancias.
- **Límite visual:** Solo es factible graficar y analizar una característica a la vez.
- **Suposición de independencia:** Al igual que los PDP, los gráficos ICE asumen erróneamente que las características son independientes entre sí. Si las variables están muy correlacionadas, la técnica creará combinaciones de datos irreales al generar los puntos de la gráfica

*Accumulated
Local Effects (ALE)*

Los gráficos de ***Accumulated Local Effects - Efectos Locales Acumulados (ALE)*** son una técnica de explicabilidad *post-hoc*, *global* y *agnóstica del modelo*. Su propósito principal es resolver el mayor defecto que tienen los métodos PDP e ICE: **el problema de las variables altamente correlacionadas**

¿Cómo funciona ALE y en qué se diferencia de PDP?

En lugar de crear datos sintéticos irreales y promediarlos, ALE introduce dos mejoras matemáticas críticas:

1. **Uso de la distribución condicional:** En lugar de alterar todo el conjunto de datos de golpe, ALE divide el rango de la característica que estamos analizando en pequeños intervalos o "ventanas" locales. Solo evalúa las instancias de entrenamiento reales que caen dentro de ese intervalo concreto.
2. **Calcula diferencias en lugar de promedios:** Para medir el efecto real de la variable, dentro de cada pequeño intervalo, ALE toma las predicciones de los ejemplos y calcula la **diferencia** en la predicción al evaluar el modelo en el límite superior y luego en el límite inferior de ese intervalo

Interpretación del gráfico

Línea naranja

Clase 1 (Primera): Tiene un impacto positivo alto (cercano a +0.08). Estar en primera clase **aumenta significativamente** las posibilidades de supervivencia según el modelo.

Clase 2 (Segunda): Sigue teniendo un impacto positivo, pero más bajo (alrededor de +0.02). Todavía ayuda a sobrevivir, pero mucho menos que la primera.

Clase 3 (Tercera): El impacto cae drásticamente por debajo de cero (cercano a -0.11). Estar en tercera clase **reduce drásticamente** la probabilidad de que el modelo te considere un superviviente.


Línea celeste

Clase 1: El impacto está muy por debajo de cero (-0.08). Reduce la probabilidad de ser clasificado como "No Superviviente".

Clase 2: El impacto sigue siendo negativo (-0.02).

Clase 3: El impacto se dispara hacia arriba (más de +0.11). Estar en tercera clase **aumenta muchísimo** la probabilidad de que el modelo prediga que el pasajero no sobrevivió.

ALE Plot para Clase de Pasajero (Clase: Superviviente)



- **Ventajas:**

- Es imparcial (*unbiased*) y **funciona de forma fiable cuando las características están correlacionadas**, ya que evita generar combinaciones de datos poco realistas.

- **Desventajas:**

- **Su lógica es menos intuitiva:** A diferencia de los PDP, cuya explicación matemática es un simple promedio, la construcción paso a paso de ALE (sumar diferencias locales en intervalos) es mucho más compleja de explicar a una audiencia de negocios o partes interesadas no técnicas.
- Aunque maneja bien la correlación, se debe seguir teniendo precaución al interpretar variables que estén *extremadamente* correlacionadas, ya que en la vida real siempre variarán de la mano.

Característica	Partial Dependence Plots (PDP)	Individual Conditional Expectation (ICE)	Accumulated Local Effects (ALE)
Alcance	Global. Muestra el comportamiento promedio del modelo sobre todo el conjunto de datos.	Local. Analiza y visualiza el comportamiento a nivel de cada instancia o ejemplo individual.	Global. Analiza el efecto general en el modelo, pero se construye a partir de acumulaciones locales.
Fundamento Teórico	Mide el efecto marginal promediando las predicciones resultantes al sustituir y forzar valores específicos de una característica en todo el conjunto de datos.	Extiende los PDP trazando una línea separada por cada ejemplo individual para ver cómo cambia su predicción al variar la característica, en lugar de calcular un promedio.	Calcula el efecto midiendo diferencias en predicciones dentro de pequeños intervalos (distribución condicional) reales, y luego acumula estos efectos locales a lo largo de la distribución.

Característica	Partial Dependence Plots (PDP)	Individual Conditional Expectation (ICE)	Accumulated Local Effects (ALE)
Estabilidad (Manejo de correlaciones)	Baja. Asume ingenuamente que las características son independientes. Si hay multicolinealidad, fuerza la creación de combinaciones de datos sintéticos físicamente improbables o irreales, sesgando el análisis.	Baja. Sufre de la misma vulnerabilidad subyacente que los PDP, ya que también asume independencia entre las características al alterar los datos.	Alta (Robusta). Diseñado específicamente para resolver el problema de variables correlacionadas. Usa distribuciones condicionales reales, evitando crear o evaluar datos fuera de la distribución natural.
Costo Computacional e Implementación	Bajo a Medio. Es intuitivo y muy fácil de implementar e interpretar. Sin embargo, evaluar múltiples sustituciones en todas las instancias puede ser costoso.	Alto (Visualmente). Computa predicciones para todas las instancias, pero el verdadero costo es visual: genera gráficos abarrotados y ruidosos (efecto "espagueti") que requieren muestreos para ser legibles.	Bajo computacionalmente, pero alta complejidad de interpretación. Su lógica matemática de acumular diferencias en intervalos es mucho menos intuitiva de explicar a audiencias de negocios.

Característica	Partial Dependence Plots (PDP)	Individual Conditional Expectation (ICE)	Accumulated Local Effects (ALE)
Interacciones y Heterogeneidad	Pobre. Al promediar los efectos, oculta o "cancela" relaciones heterogéneas subyacentes o interacciones complejas. Solo es útil para visualizar 1 o 2 variables a la vez.	Excelente. Destaca precisamente en revelar la heterogeneidad y las interacciones ocultas que los PDP promedian, mostrando excepciones a la tendencia general.	Excelente (Aislada). Aísla con éxito el efecto "puro" de la característica analizada, separándolo de la influencia cruzada que tendrían otras características correlacionadas con ella.

LIME

LIME, que significa **Explicaciones Locales Interpretables Agnósticas del Modelo** (*Local Interpretable Model-agnostic Explanations*), es una técnica de explicabilidad *post-hoc* basada en perturbaciones. Al ser una técnica agnóstica, **trata a cualquier modelo entrenado como si fuera una API o caja negra**, lo que permite utilizarla independientemente de la arquitectura del modelo subyacente y aplicarla a diversos tipos de datos, como imágenes, texto o conjuntos de datos tabulares.

El objetivo principal de LIME es **explicar el razonamiento detrás de una predicción individual específica**, motivo por el cual se le considera una técnica "local".

- LIME significa Explicaciones Locales Interpretables e Independientes del Modelo. Es una técnica de **explicabilidad post hoc** basada en perturbaciones.
- LIME puede utilizarse para modelos de regresión o clasificación, aunque en la práctica se utiliza principalmente para modelos de clasificación.
- LIME funciona modificando regiones de una imagen, activándolas o desactivándolas y repitiendo las inferencias para determinar qué regiones influyen más en la predicción del modelo.
- LIME utiliza un modelo intrínsecamente interpretable para medir la influencia o importancia de las características de entrada.

Para lograr esto, LIME funciona siguiendo estos pasos fundamentales:

1. Selecciona una instancia o ejemplo específico cuya predicción se desea entender.
2. **Crea un nuevo conjunto de datos generando múltiples variaciones (perturbaciones) de la entrada original.** Por ejemplo, si analiza una imagen, apaga u oculta ciertas regiones ("superpíxeles"), y si analiza texto, elimina palabras al azar.
3. Introduce estas muestras perturbadas en el modelo complejo original para registrar cómo cambian sus predicciones ante estas pequeñas variaciones.
4. Pondera estas nuevas predicciones dándoles mayor peso a aquellas muestras perturbadas que tienen mayor proximidad o parecido con el ejemplo original.
5. Finalmente, **entrena un modelo sustituto intrínsecamente interpretable y simple** (como una regresión lineal) sobre este nuevo conjunto de datos ponderado.

La premisa de LIME es que, aunque el modelo global sea extremadamente complejo y no lineal, puede ser aproximado por un modelo simple (como una regresión lineal o un árbol de decisión corto) si nos limitamos a un entorno local muy pequeño alrededor de un punto de datos específico. Para lograr esto, LIME realiza los siguientes pasos:

1. **Perturbación:** Genera un conjunto de datos sintéticos alrededor de la instancia x mediante la adición de ruido o la desactivación de características.
2. **Pesado por Proximidad:** Asigna un peso a cada muestra perturbada basado en su distancia a la instancia original utilizando un kernel de proximidad (generalmente un kernel exponencial).
3. **Entrenamiento del Modelo Simple:** Entrena un modelo interpretable g (por ejemplo, una regresión lineal con regularización Lasso para asegurar la dispersión) minimizando una función de pérdida que mide qué tan bien g predice las salidas del modelo complejo f en el entorno local.
4. **Explicación:** Los coeficientes del modelo lineal g sirven como explicaciones, indicando qué características contribuyeron más a la decisión local.

LIME es ampliamente valorado por su flexibilidad, permitiendo explicar modelos de texto, imágenes y datos tabulares. Sin embargo, enfrenta desafíos de inestabilidad: ejecutar LIME dos veces sobre la misma instancia puede producir explicaciones ligeramente diferentes debido a la aleatoriedad en el proceso de perturbación. Además, la definición de "vecindad" (el ancho del kernel) es a menudo arbitraria y tiene un impacto masivo en la fidelidad de la explicación resultante.

Ventajas y desventajas de LIME para texto

Pros	Cons
• LIME is model agnostic, so it can be applied to any machine learning model in any framework. • This is an easy-to-implement Python package with easy-to-interpret visualizations. • LIME is available in the Language Interpretability Tool (LIT).	• The proximity measure uses a kernel smoothing that can be very sensitive to the kernel width. Slight modifications to the kernel width can lead to quite different explanations. • LIME provides an explanation based on a linear approximation of the local behavior of a model. It does not work as well for highly nonlinear models. • LIME doesn't take into account the sequential nature of the text data, and repeated words in a sentence are treated as a single feature. • The publicly available Python package implementation <code>lime</code> is only for text classification.

Ventajas y desventajas de LIME para imágenes

Pros

- LIME is a very popular technique for producing pixel-level attributions.
- It is easy to implement and has a well-maintained Python implementation (see [GitHub repository](#)).
- It has an intuitive and easy-to-explain algorithm and implementation.
- There are a wide variety of visualization options.

Cons

- Explanations are brittle and may not be accurate. Because LIME is a local interpretation of a complex model, explanations can be particularly bad for highly nonlinear models.
- LIME is prone to misidentifying background regions as influential.
- Explanations can be very slow to generate, depending on the complexity of your model, since it queries the model multiple times on perturbations of the input.

SHAP values

SHAP (SHapley Additive exPlanations) es un método de explicabilidad que utiliza la teoría de juegos cooperativos para cuantificar la influencia o contribución individual de cada característica (feature) en una predicción específica de un modelo de Machine Learning.

Aunque los términos "Valores Shapley" y "Valores SHAP" suelen usarse como sinónimos, técnicamente **los Valores Shapley representan la teoría matemática subyacente**, mientras que **SHAP es la implementación algorítmica específica** diseñada para calcular estos valores en modelos de ML.

Para entender su funcionamiento, SHAP plantea la siguiente analogía basada en la teoría de juegos:

- El "**juego cooperativo**" es el modelo en sí y la predicción que este genera.
- Los "**jugadores**" son las diferentes características o variables de entrada (features) del conjunto de datos.
- Las "**coaliciones**" son los distintos subconjuntos o agrupaciones de características que interactúan entre sí.
- El "**premio**" (**payoff**) es el resultado final de la predicción.

En este contexto, un valor SHAP representa **cuánto contribuye matemáticamente un "jugador" (característica) para desviar la predicción del modelo desde un valor base (el promedio esperado de las predicciones) hasta el valor final predicho para esa instancia en particular.** Esta contribución calculada puede ser positiva (empuja la predicción hacia arriba) o negativa (empuja la predicción hacia abajo)

La robustez de SHAP reside en que es el único método de atribución que satisface cuatro propiedades matemáticas críticas que garantizan una interpretación consistente y honesta :

1. **Eficiencia (Exactitud Local):** La suma de todas las atribuciones (valores SHAP) debe ser igual a la diferencia entre la predicción del modelo y el valor base esperado. Esto asegura que toda la predicción esté explicada.
2. **Simetría:** Si dos características contribuyen de manera idéntica a todas las coaliciones posibles, sus valores SHAP deben ser iguales.
3. **Jugador Nulo (Dummy):** Una característica que no tiene impacto en la predicción del modelo en ninguna circunstancia debe tener un valor SHAP de cero.
4. **Consistencia (Aditividad):** Si un modelo cambia de manera que la contribución marginal de una característica aumenta (o se mantiene), su valor SHAP no debe disminuir. Esto evita que el método favorezca injustamente a ciertas variables cuando el modelo se vuelve más sensible a ellas.

SHAP (SHapley Additive exPlanations) presenta varias ventajas clave frente a otros métodos de importancia de variables (como *Permutation Feature Importance* o LIME):

- **Fuertes garantías matemáticas (Axiomas de Equidad):** SHAP se fundamenta en la teoría de juegos cooperativos y cumple con cuatro propiedades o axiomas fundamentales: eficiencia, simetría, jugador nulo y aditividad/linealidad. Esto le **proporciona mayores garantías matemáticas sobre la precisión y solidez de las explicaciones** en comparación con métodos basados en perturbaciones como LIME.
- **Propiedad de Eficiencia (Aditividad exacta):** Una de las ventajas más destacadas de SHAP es que **la suma de todas las atribuciones (valores SHAP) de las variables equivale exactamente a la predicción final del modelo** (más específicamente, explica la diferencia entre la predicción base o promedio y la predicción final de esa instancia). Otros métodos relativos o basados en porcentajes no suelen sumar el total de la predicción, lo que dificulta su razonamiento matemático.

- **Versatilidad para explicaciones locales y globales:** Mientras que otros métodos son estrictamente locales o globales, los valores SHAP **pueden usarse tanto para entender una predicción individual (local), como para analizar un subgrupo (cohorte) o para explicar el comportamiento global del modelo** agregando los resultados de múltiples instancias.
- **Manejo superior al evaluar variables correlacionadas:** A diferencia del método de Permutación de Importancia de Variables (*Permutation Feature Importance*), que evalúa el impacto de una variable alterando sus datos asumiendo que son independientes (lo cual falla y da resultados engañosos si están muy correlacionadas), SHAP es un método puramente observacional. SHAP **infiere la influencia de las variables analizando el modelo frente a múltiples combinaciones (coaliciones) de características**, evitando el problema de simular datos falsos irreales.

- **Agnóstico al modelo (Portabilidad):** Al ser una técnica agnóstica que evalúa el modelo desde el exterior, **SHAP se puede aplicar a cualquier arquitectura de Machine Learning.** Esto permite a los ingenieros intercambiar diferentes modelos y seguir comparando las explicaciones generadas bajo la misma métrica, sin tener que rediseñar el marco de explicabilidad
- **Excelentes herramientas de visualización:** La librería de SHAP **proporciona representaciones visuales intuitivas y avanzadas** (como gráficos de cascada o *waterfall*, gráficos de fuerza y *beeswarm plots*) que facilitan la comprensión por parte de los *stakeholders*. Estas herramientas muestran gráficamente cómo cada característica empuja la predicción hacia arriba o hacia abajo respecto al valor base.

Ventajas estratégicas de SHAP frente a otros métodos

SHAP ofrece múltiples beneficios en comparación con métodos tradicionales como la importancia por impureza (Gini) o la importancia por permutación :

- **Dualidad Local y Global:** SHAP proporciona explicaciones para cada fila de datos (local), pero al promediar la magnitud de estos valores sobre todo el dataset, se obtiene una medida de importancia global mucho más fiable que la de otros métodos.
- **Direccionalidad:** A diferencia de PFI, que solo indica si una variable es importante, los valores SHAP indican si una variable está empujando la predicción hacia arriba o hacia abajo (contribución positiva o negativa).
- **Manejo de Correlaciones:** A través de variantes como TreeSHAP, el método puede manejar dependencias entre variables de manera más elegante que los métodos agnósticos puros, utilizando expectativas condicionales para evitar datos irreales.
- **Visualización Rica:** SHAP permite generar gráficos de "fuerza" (Force Plots) para ver cómo las variables compiten en una sola predicción, y gráficos de resumen (Summary Plots) que muestran la distribución del impacto de cada variable en todo el dataset.

Característica	LIME	SHAP
Alcance	Local.	Local y Global.
Fundamento Teórico	Basado en modelos sustitutos locales . Crea datos sintéticos (perturbaciones) alrededor del ejemplo a explicar y entrena un modelo simple intrínsecamente interpretable (como una regresión lineal) sobre esos datos para aproximar el modelo complejo	Basado en la teoría de juegos cooperativos . Cuantifica el impacto de una característica probando todas las combinaciones ("coaliciones") posibles de variables presentes y ausentes para calcular su contribución marginal exacta
Estabilidad	Baja (Frágil / Brittle) . Sus explicaciones pueden ser inestables. Es extremadamente sensible a sus hiperparámetros, especialmente al "ancho del kernel" (<i>kernel width</i>), lo que significa que pequeños cambios de configuración pueden dar explicaciones totalmente distintas.	Alta y Robusta . Está respaldado por fuertes garantías matemáticas (axiomas de equidad: eficiencia, simetría, jugador nulo y aditividad). Asegura que la suma de las contribuciones iguale a la predicción final.

Característica	LIME	SHAP
Costo Computacional	Medio a Alto. Aunque evita la explosión combinatoria de SHAP, requiere generar miles de perturbaciones de datos (ej. 1000 ejemplos) y pasarlas por el modelo complejo para entrenar la regresión lineal sustituta, lo que puede ser lento	Muy Alto. Calcular los valores exactos es computacionalmente prohibitivo al evaluar todas las combinaciones posibles (aumenta exponencialmente). En la práctica exige métodos de aproximación (como Sampled SHAP o KernelSHAP) o algoritmos específicos (TreeSHAP)
Interacciones	Pobre. Dado que el modelo sustituto que utiliza suele ser una regresión lineal simple, asume una relación lineal local, lo que le impide capturar interacciones complejas o altamente no lineales entre variables	Excelente. Al evaluar las características en "coaliciones" (agrupaciones), el valor SHAP de una variable captura intrínsecamente cómo interactúa y se ve influenciada por la presencia de otras variables

Métodos de estimación de SHAP:

KernelSHAP vs TreeSHAP



Dado que calcular los valores de Shapley exactos requiere evaluar 2^n combinaciones de características, lo cual es computacionalmente prohibitivo para modelos con muchas variables, se han desarrollado métodos de estimación.

- **KernelSHAP:** Es un método agnóstico que utiliza una regresión lineal ponderada similar a LIME, pero con un diseño de kernel específico (el Kernel SHAP) que garantiza que los coeficientes resultantes sean valores de Shapley. Es lento pero aplicable a cualquier modelo.
- **TreeSHAP:** Es un algoritmo específico para modelos basados en árboles (como XGBoost, LightGBM y Random Forest). Aprovecha la estructura jerárquica del árbol para calcular los valores de Shapley en tiempo polinomial ($O(T L D^2)$), lo que lo hace órdenes de magnitud más rápido que KernelSHAP y permite la interpretación de millones de instancias en segundos.

Ventajas y desventajas de SHAP

Pros

- Shapley values can be used for individual predictions, cohorts, and to globally explain the model.
- Attributions sum to the total predicted value.
- The values provide an intuitive understanding for stakeholders.

Cons

- Feature influence is often conflated with causality by practitioners, end users, and stakeholders.
- These values are computationally intensive and difficult to use with models with more than ~ 100 features.
- Choosing a good baseline can be difficult.

